

基于 TextCNN 模型的实时身份检测算法研究及仿真

姚伟,黄晓芳*

(西南科技大学计算机科学与技术学院,四川 绵阳 621000)

摘要:用户行为数据的复杂性和多样性使得现有算法难以准确提取区分用户身份的特征,进而影响检测系统的准确性,易产生误判或漏判。因此,提出基于 TextCNN 模型的实时身份检测算法。引入 TextCNN 模型搭建实时身份检测框架,以此为基础,应用 TextCNN 模型——输入层、嵌入层、卷积层、池化层、全连接层与输出层,计算 PC 端和 WEB 端用户行为数据特征数值,并确定其对应的融合权重。融合这两端的数据特征后,制定用户身份检测规则,执行制定规则即可以实现用户身份的实时检测。实验结果显示:应用提出算法在 PC 端行为数据特征提取方面取得了显著成效。算法提取的特征与实际结果高度一致,特征提取完整度最高达到 95%,且用户身份检测的 F1 分数最高为 0.92,证明了该算法具有出色的应用性能。

关键词:用户行为;身份检测;行为数据;模型

中图分类号:TP391 **文献标识码:**B

Research and Simulation of Real-Time Identity Detection Algorithm Based on TextCNN Model

YAO Wei, HUANG Xiao-fang*

(School of Computer Science and Technology, Southwest University of Science and Technology, Mianyang Sichuan 621000, China)

ABSTRACT: The complexity and diversity of user behavior data make it difficult for existing algorithms to accurately extract the characteristics that distinguish user identity, which further affects the accuracy of the detection system, and is prone to miscarriage or omission of judgment. Therefore, a real-time identity detection algorithm based on TextCNN model is proposed. The TextCNN model is introduced to build a real-time identity detection framework. On this basis, the TextCNN model—input layer, embedded layer, convolution layer, pooling layer, full connection layer and output layer—is applied to calculate the characteristic values of user behavior data on the PC side and the WEB side, and determine their corresponding fusion weights. After fusing the data characteristics of these two ends, the user identity detection rules are formulated, and the real-time detection of user identity can be realized by executing the formulated rules. The experimental results show that the proposed algorithm has achieved remarkable results in the feature extraction of PC behavior data. The features extracted by the algorithm are highly consistent with the actual results. The integrity of feature extraction is up to 95%, and the F1 score of user identity detection is up to 0.92, which proves that the algorithm has excellent application performance.

KEYWORDS: User behavior; Identity detection; Behavioral data; Model

1 引言

身份认证与识别技术是保障信息安全、维护社会秩序的重要基石,尤其是在网络安全威胁日益严峻的背景下,传统

的身份认证方式已难以满足复杂多变的安全需求^[1]。然而,由于个体特征的复杂性和多样性,如何提取有效、稳定的特征信息成为算法设计的关键;另一方面,实时性要求算法在处理速度上达到较高的标准,以满足实际应用的需求^[2]。因此,研究高效、准确的实时身份检测算法具有重要价值。

刘红等人^[3]设计的 UI-STDD 身份识别算法融合了时空分布与双向时空依赖,包括时空序列、时间偏好与空间位置模块。时空序列模块用双向 LSTM 刻画用户移动模式,时间

基金项目:四川省科技厅重点研发项目(2022YFG0321);四川省自然科学基金(2022NSFC0916)

收稿日期:2024-04-06 修回日期:2024-06-11

偏好模块定义用户个性化模式,空间位置模块挖掘用户行为信息并量化空间邻近性。但多模块结构可能导致数据丢失,降低身份识别率。张广胜等人^[4]深入研究了用户身份识别方法,对其进行了分类和适用场景阐述,并指出了当前研究的挑战。此研究主要针对现有用户身份识别方法进行了说明与验证,发现其均存在着一定的缺陷,无法满足现今网络发展需求;杜航原等人^[5]针对异常用户行为,构建用户-设备二分图,并提出自监督异常检测模型 S-SADM。该模型通过编码表示用户节点,利用自监督学习机制实现异常检测。但 S-SADM 在应用前需多次迭代训练,算力消耗大,导致异常检测能耗较高。Cheng Wang 等人^[6]以在线社交网络为研究对象,采集用户行为数据,将其整合为复合行为记录,由多维低质量数据组成,实现了用户身份的有效检测。此研究由于考虑了较多的用户行为模式,致使研究数量体量剧增,降低了用户身份检测的效率。

因此,提出基于 TextCNN 模型的实时身份检测算法。

2 实时身份检测算法

2.1 实时身份检测框架搭建

根据已有研究文献分析可知,现有算法主要是依据用户单一行为数据进行身份检测,这种限制使得所提取的身份特征信息不足,进而影响了身份检测的准确性。因此,引入 TextCNN 模型,构建实时身份检测框架,旨在通过更全面的数据分析和特征提取,提升身份检测的准确性和可靠性。实时身份检测框架如图 1 所示。




图 1 实时身份检测框架图

如图 1 所示,搭建框架应用了两种用户行为数据,分别为 PC 端行为数据与 WEB 端行为数据,其来源于 PC 系统日志与 WEB 浏览日志,将其输入至 TextCNN 模型中提取 PC 端行为数据特征数值与 WEB 端行为数据特征数值,获取用户行为数据匹配分数融合权重,计算最终的用户行为数据融合结果,以此为基础,得出最终的实时身份检测结果^[7-8]。

2.2 PC 端与 WEB 端用户行为数据特征数值计算

根据上述搭建框架,应用 TextCNN 模型来计算 PC 端与 WEB 端用户行为数据的特征数值,为实时身份检测提供精准依据。TextCNN 模型通过输入层接收数据,嵌入层将数据进行向量化表示,卷积层与池化层提取关键特征,最后全连接层与输出层完成分类或识别任务,确保实时身份检测的准确性和高效性。

1) 输入层

将 PC 系统日志与 WEB 浏览日志加载到 TextCNN 模型中,对其预处理以此降低用户行为数据复杂度,保障用户行为数据整体质量^[9]。

设置原始用户行为数据——PC 系统日志与 WEB 浏览日志为 $X = \{x_1, x_2, \dots, x_i, \dots, x_n\}$ 与 $Y = \{y_1, y_2, \dots, y_j, \dots, y_m\}$, 为了方便研究的进行,将其预处理为编码形式,表达式为:

$$\begin{cases} X' = \alpha_1 \times \psi \{X\} \pm \varepsilon_1 \\ Y' = \alpha_2 \times \psi \{Y\} \pm \varepsilon_2 \end{cases} \quad (1)$$

式(1)中, X' 与 Y' 表示编码形式的 PC 端与 WEB 端用户行为数据; α_1 与 α_2 表示 PC 端与 WEB 端用户行为数据编码形式转换辅助参量; $\psi \{ \cdot \}$ 表示转换函数; ε_1 与 ε_2 表示 PC 端与 WEB 端用户行为数据的编码误差调整项。

2) 嵌入层

将输入层输出的 X' 与 Y' 转换为向量形式,依据字典找到词语在向量形式中的表征向量,遍历全部用户行为数据编码,获得用户行为数据向量矩阵^[10],表达式为:

$$\begin{cases} \hat{X} = I^p \times \Gamma \{X'\} \\ \hat{Y} = I^p \times \Gamma \{Y'\} \end{cases} \quad (2)$$

式(2)中, $\hat{X}$ 与 $\hat{Y}$ 表示向量矩阵形式的 PC 端与 WEB 端用户行为数据; I^p 表示标准单位向量矩阵; $\Gamma \{ \cdot \}$ 表示向量矩阵转换函数。

3) 卷积层

卷积层针对用户行为数据矩阵,通过一维卷积提取特征,采用多个卷积核获取多维度特征向量,卷积核宽度与数据维度相匹配,确保特征提取的有效性^[11]。依据上述描述过程,获取用户行为数据卷积特征向量,表达式为:

$$\begin{cases} \delta_x = \sum_{t=1}^T \chi \{ \hat{X} \} + a_1 \\ \delta_y = \sum_{t=1}^T \chi \{ \hat{Y} \} + a_2 \end{cases} \quad (3)$$

式(3)中, δ_x 与 δ_y 表示 PC 端与 WEB 端用户行为数据的卷积特征向量; t 与 T 表示当前卷积操作次数与最大卷积操作次数; $\chi \{ \cdot \}$ 表示卷积核操作函数; a_1 与 a_2 表示 PC 端与 WEB 端用户行为数据的卷积尺度因子。

4) 池化层

卷积层输出的特征向量维度较高,易导致运算效率低和过拟合^[12]。池化层进一步处理这些特征向量,采用 1-max pooling 简化运算,从每个卷积特征向量中选取最大向量作为

代表,获得更具代表性的用户行为数据特征向量,表达式为:

$$\begin{cases} \zeta_x = \frac{\kappa[\text{Pooling}\{\delta_x\}]}{k \times b_1} \\ \zeta_y = \frac{\kappa[\text{Pooling}\{\delta_y\}]}{p \times b_2} \end{cases} \quad (4)$$

式(4)中, ζ_x 与 ζ_y 表示PC端与WEB端用户行为数据的池化特征向量; $\kappa[\cdot]$ 表示特征向量深度提取函数; $\text{Pooling}\{\cdot\}$ 表示池化函数; k 与 p 表示PC端与WEB端用户行为数据的特征占比参量; b_1 与 b_2 表示PC端与WEB端用户行为数据池化特征向量提取因子。

5) 全连接层

在TextCNN模型中设置两层全连接层,用于用户行为数据特征分类。首层采用ReLU函数增加非线性;次层采用Sigmoid函数提升特征分类的精确度^[13]。通过这两层全连接层,获得PC端与WEB端用户行为数据的特征分类结果,记为 $C_x = \{C_x^1, C_x^2, \dots, C_x^N\}$ 与 $C_y = \{C_y^1, C_y^2, \dots, C_y^M\}$,将其传输给输出层,为用户行为数据特征数值的计算提供支撑。

6) 输出层

以全连接层获得的用户行为数据特征分类结果为依据,根据不同特征贡献程度的不同,计算与输出PC端与WEB端用户行为数据特征数值,其表达式为:

$$\begin{cases} \lambda_x = \sum_{i=1}^N \omega_i \cdot C_x^i \\ \lambda_y = \sum_{j=1}^M \omega_j \cdot C_y^j \end{cases} \quad (5)$$

式(5)中, λ_x 与 λ_y 表示PC端与WEB端用户行为数据特征数值; N 与 M 表示PC端与WEB端用户行为数据特征的总类别; ω_i 与 ω_j 表示 C_x^i 与 C_y^j 的贡献程度。

上述过程完成了PC端与WEB端用户行为数据特征数值的计算,为最终研究目标的实现奠定坚实的基础。

2.3 用户行为数据特征数值融合权重确定

通过计算PC端与WEB端用户行为数据的特征数值,获得了丰富的身份特征信息。然而,不同终端和环境数据的重要性存在差异,因此确定融合权重至关重要^[14]。这一步骤将多源数据有效整合,提取关键特征,形成全面准确的用户身份画像,从而提升实时身份检测的准确性和可靠性。

以TextCNN模型全连接层输出的特征直接使用概率作为匹配分数,即融合权重,分别记为 ϑ_x 与 ϑ_y ,设置基于PC端用户行为数据的身份检测子模型权重为 v_1 ,基于WEB端用户行为数据的身份检测子模型权重为 v_2 ,则融合权重(匹配分数)的计算公式为

$$\begin{cases} \vartheta_x = \frac{v_1}{v_1 + v_2} \\ \vartheta_y = \frac{v_2}{v_1 + v_2} \end{cases} \quad (6)$$

依据式(6)输出结果,计算PC端与WEB端用户行为数

据特征数值融合结果,表达式为:

$$Q = \vartheta_x \lambda_x + \vartheta_y \lambda_y \quad (7)$$

为了保障用户行为数据特征数值融合结果的精确性,对融合权重进行反向传播与训练^[15-16],误差函数表达式为:

$$E = \frac{(Q - Q_r)^2}{2} \quad (8)$$

式(8)中, E 表示融合权重训练误差; Q_r 表示用户行为数据特征数值融合真实数值。

当式(8)输出结果 E 达到最小值时,融合权重训练结束,此时融合权重取值最为精准,记为 $\hat{\vartheta}_x$ 与 $\hat{\vartheta}_y$,将其输入至式(7)中,获取PC端与WEB端用户行为数据特征数值融合结果 $\hat{Q}$,制定用户身份检测规则:当 $\hat{Q} \geq \xi$ 时,认定该用户具有进入网络的权限;当 $\hat{Q} < \xi$ 时,认定该用户无进入网络的权限。 ξ 表示用户身份检测阈值,根据实际网络情况进行具体的设置。

综上所述,在TextCNN模型的支撑下实现了网络用户身份的实时检测,为身份检测提供更有有效的算法支撑。

3 提出算法仿真测试

为了验证基于TextCNN模型的实时身份检测算法的性能,选取文献[3]、文献[4]与文献[5]作为对比算法1、对比算法2与对比算法3,联合提出算法共同进行用户身份检测实验,以此来验证提出算法的应用性能。

3.1 实验数据准备

收集实验室100个用户的Windows操作系统行为日志数据和Chrome浏览器上的浏览行为数据,采集到的PC端操作日志记录有160多万条以及WEB端浏览行为记录200多万条。其中,正样本数据是正常用户(有限额)的行为数据样本,负样本是其它用户(无限额)的行为数据样本。原始PC端与WEB端用户行为数据如图2所示。

将采集到的用户行为数据放入深度学习模型中训练,为满足TextCNN模型的数据输入格式,将日志文本信息转换为编码形式。首先,对日志文本数据进行预处理,清除掉重复信息避免深度学习模型过拟合;其次对日志文本数据分词处理,在这一步操作中,将文本中的句子转换为词语并且用空格分隔开。通过已经分词的日志文本数据,统计每一个词语出现的频率,并且根据出现频率从高到低进行编码,会得到一个词语对应编号的字典,等待编码转换为向量的操作,至此用户的行为日志数据预处理完毕,为后续用户行为数据的应用提供一定的便利。

3.2 TextCNN模型训练

TextCNN模型是提出算法应用的主要手段,决定着提出算法的应用效果。因此,在实验进行之前,对TextCNN模型

类型	日期	时间	来源	分类	事件	用户	计算机
审核成功	2021-9-12	14:31:49	Security	登录失败	538	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:31:49	Security	登录失败	582	SYSTEM	EJNIT-WO...
审核成功	2021-9-12	14:31:49	Security	登录失败	576	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:31:49	Security	登录失败	538	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:31:49	Security	登录失败	532	SYSTEM	EJNIT-WO...
审核成功	2021-9-12	14:31:49	Security	账户登录	680	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:31:28	Security	登录失败	538	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:30:58	Security	登录失败	583	SYSTEM	EJNIT-WO...
审核成功	2021-9-12	14:30:50	Security	登录失败	576	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:30:50	Security	登录失败	538	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:30:50	Security	登录失败	532	SYSTEM	EJNIT-WO...
审核成功	2021-9-12	14:30:50	Security	账户登录	680	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:29:43	Security	登录失败	540	ADMINISTRATOR	EJNIT-WO...
审核成功	2021-9-12	14:29:39	Security	登录失败	576	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:29:39	Security	登录失败	538	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:29:39	Security	登录失败	532	SYSTEM	EJNIT-WO...
审核成功	2021-9-12	14:29:39	Security	账户登录	680	Administrator	EJNIT-WO...
审核成功	2021-9-12	14:29:39	Security	登录失败	576	LOCAL SERVICE	EJNIT-WO...
审核成功	2021-9-12	14:29:39	Security	登录失败	538	LOCAL SERVICE	EJNIT-WO...

(a) PC端用户行为数据

序号	姓名	访问时间	访问地址	访问标题	所属分类
1	ITNA-PC	2020-12-08 18:03:46	cdn.vender.com	v traffic return v.2.0	未知分类
2	ITNA-PC	2020-12-08 18:03:46	cdn.vender.com		未知分类
3	ITNA-PC	2020-12-08 18:03:46	cdn.vender.com		未知分类
4	ITNA-PC	2020-12-08 18:03:46	cdn.vender.com		未知分类
5	ITNA-PC	2020-12-08 18:03:46	cdn.vender.com		未知分类
6	ITNA-PC	2020-12-08 18:03:46	cdn.vender.com	v traffic return v.2.0	未知分类
7	ITNA-PC	2020-12-08 18:03:44	cdn.vender.com		计算机与电子技术
8	ITNA-PC	2020-12-08 18:03:44	cdn.vender.com		计算机与电子技术
9	ITNA-PC	2020-12-08 18:03:44	cdn.vender.com		未知分类
10	ITNA-PC	2020-12-08 18:03:43	cdn.vender.com		计算机与电子技术
11	ITNA-PC	2020-12-08 18:03:43	cdn.vender.com		未知分类
12	ITNA-PC	2020-12-08 18:03:43	cdn.vender.com		未知分类
13	ITNA-PC	2020-12-08 18:03:43	cdn.vender.com		计算机与电子技术
14	ITNA-PC	2020-12-08 18:03:43	cdn.vender.com		未知分类
15	ITNA-PC	2020-12-08 18:03:42	cdn.vender.com		广告与弹出窗口

(b) WEB端用户行为数据

图2 原始PC端与WEB端用户行为数据示例图

进行训练,相关参数设置情况如表1所示。

表1 TextCNN模型训练参数设置表

训练参数	数值设置	参数描述
学习率	0.001	参数更新步长
批处理大小	32	迭代训练时使用样本数量
卷积核大小	[3,4,5]	卷积核窗口尺寸
卷积核数量	100	每个卷积核个数
池化方式	最大池化	保留最显著特征
正则化参数	0.0001	正则化项的权重
迭代次数	100	训练数据集的遍历次数

依据上述设置的训练参数,制定TextCNN模型训练程序,具体如图3所示。




图3 TextCNN模型训练程序图

依据图3所示程序对TextCNN模型进行训练,为后续实验进行提供支撑。

3.3 实验结果分析

以某一用户一个月PC端行为数据为实验对象,应用提出算法、对比算法1、对比算法2与对比算法3对PC端行为数据特征——PV进行提取,提取结果如图4所示。




图4 PC端行为数据特征提取结果示意图

如图4所示,应用提出算法获得的PC端行为数据特征提取结果与实际结果几乎一致,而应用对比算法1、对比算法2与对比算法3获得的PC端行为数据特征提取结果与实际结果差异性较大,表明提出算法用户行为数据特征提取性能更强。

将100个用户及其相关行为数据随机划分为10个组别,应用提出算法、对比算法1、对比算法2与对比算法3对用户行为数据特征进行提取,计算用户行为数据特征提取完整度,具体如图5所示。




图5 用户行为数据特征提取完整度示意图

如图5数据所示,应用提出算法获得的用户行为数据特征提取完整度均大于对比算法1、对比算法2与对比算法3,其最大值达到了95%,说明提出算法用户行为数据特征提取性能更佳,可以为用户身份检测提供更加充足的数据支撑。

F1分数综合考虑了精确率(Precision)和召回率(Recall)两个因素,能够更全面地反映用户身份检测性能。

F1 分数的取值范围在 0 到 1 之间,其中 1 表示用户身份检测性能最佳;而 0 则表示用户身份检测性能最差。通过实验获得用户身份检测 F1 分数如图 6 所示。




图 6 用户身份检测 F1 分数示意图

如图 6 所示,应用提出算法获得的用户身份检测 F1 分数均大于对比算法 1、对比算法 2 与对比算法 3,其最大值达到了 0.92,且整体保持在 0.7 以上,说明提出算法用户身份检测性能更佳。这是因为提出算法引入了 TextCNN 模型,这一模型能够自动提取的特征信息,通过卷积和池化操作,有效捕捉用户行为数据中的关键特征。相较于传统方法,TextCNN 模型能够更全面地利用数据,提高了特征提取的准确性和效率。

4 结束语

针对用户行为数据的复杂性和多样性导致现有算法难以准确提取区分用户身份特征的问题,提出了基于 TextCNN 模型的实时身份检测算法。通过构建包含输入层、嵌入层、卷积层、池化层、全连接层与输出层的 TextCNN 模型,有效地计算了 PC 端和 WEB 端用户行为数据的特征数值,并确定了其对应的融合权重。通过融合这两端的数据特征,制定了用户身份检测规则,并成功实现了用户身份的实时检测。实验结果显示,该算法在特征提取方面取得了显著成效,特征提取完整度高达 95%,用户身份检测的 F1 分数也达到了 0.92 的高水平,充分证明了该方法在解决用户身份检测准确性问题上的有效性和实用性。

参考文献:

[1] 张克楠,李兴乾,杨胜,等. 基于最大后验概率准则的天基星座网络多用户检测方法[J]. 中国空间科学技术, 2023,43(4): 66-72.

[2] 王育齐,陈庚,钱伟中. 区块链环境下用户身份匿名的量子委托计算协议[J]. 电子科技大学学报, 2022,51(6):802-811.

[3] 刘红,朱焱,李春平. 融合多类时空轨迹特征的跨网络用户身份识别[J]. 计算机科学, 2023,50(3):114-120.

[4] 张广胜,康昭,田玲. 面向网络安全治理的用户身份识别技术与挑战[J]. 电子科技大学学报, 2023,52(3):398-412.

[5] 杜航原,李铎,王文剑. 一种面向电商网络的异常用户检测方法[J]. 计算机科学, 2022,49(7):170-178.

[6] Cheng Wang, Hangyu Zhu, Bo Yang. Composite Behavioral Modeling for Identity Theft Detection in Online Social Networks[J]. IEEE transactions on computational social systems, 2022,9(2): 428-439.

[7] Hanxiao Yu, Zesong Fei, Zhong Zheng, Neng Ye, Zhu Han. Deep Learning-Based User Activity Detection and Channel Estimation in Grant-Free NOMA[J]. IEEE transactions on wireless communications, 2023,22(4):2202-2214.

[8] 张毅,吴奇,周霜霜,等. 一种面向低轨卫星网络的高效无证书身份认证方案[J]. 计算机应用研究, 2022, 39(10):3151-3155.

[9] 吴正昊,曾国荪. 基于自适应差异化图卷积的社交网络新增恶意用户检测[J]. 计算机应用研究, 2023,40(9):2820-2825.

[10] 窦乔,吕博文,汪洲,等. 基于 TextCNN 模型的文本意图识别算法改进研究[J]. 武汉理工大学学报, 2023,45(8):133-139.

[11] 余本功,王惠灵,朱晓洁. 基于 BG-DATT-CNN 网络的方面级别情感分析[J]. 计算机工程与应用, 2022,58(24):151-157.

[12] 郑承宇,王新,王婷,等. 基于 ALBERT-TextCNN 模型的多标签医疗文本分类方法[J]. 山东大学学报:理学版, 2022,57(4):21-29.

[13] 刘俊岭,刘颖,马晨旭,等. 异构社交平台中用户身份解析[J]. 数据采集与处理, 2022,37(5):1101-1114.

[14] 张伟成,卫红权,刘树新,等. 面向 5G MEC 基于行为的用户异常检测方案[J]. 计算机工程, 2022,48(5):27-34.

[15] 张志勇,宋斌,梁腾翔,等. 基于纵向联邦学习的社交网络跨平台恶意用户检测方法[J]. 小型微型计算机系统, 2022,43(7):1541-1546.

[16] 刘珂琪,董绵绵,郜辉,等. 基于光照感知权重融合的多模态行人检测算法[J]. 激光与光电子学进展, 2023,60(16):145-155.

[作者简介]



姚 伟(1993-),男(汉族),陕西宝鸡人,硕士研究生,研究方向:身份识别、信息安全。

黄晓芳(1977-),女(汉族),四川绵阳人,博士,教授,研究方向:信息安全、协议分析、数字签名(通讯作者)。