

DOI:10.14188/j.1671-8844.2024.0261

文章编号: 1671-8844(2026)02-0308-11

基于辅助任务与知识蒸馏的中文短文本分类算法

陈昊, 金广星, 苏航

(湖北大学计算机学院, 湖北 武汉 430062)

摘要: 在短文本分类这一热门研究领域, 预训练模型虽表现出色, 但存在数据表征散布和转移学习受限等问题, 导致分类效果降低。尽管诸如 ERNIE(enhanced representation through knowledge integration) 等大模型提升了分类效果, 但由于其速度慢、资源需求大、受硬件限制等问题, 难以应用于工业生产。为此提出了基于 ERNIE 的辅助任务模型 EL(ERNIE+LAT(learning with auxiliary tasks)), 旨在验证其获取更优类别特征的可行性。针对工业任务落地需求, 同时提出知识蒸馏法, 对 EL 与 TextCNN 模型进行蒸馏训练, 以验证其在提升分类效果以及线上推理效率方面的可行性。研究验证现有预训练模型在公共数据集上的分类优势; 采用辅助任务结合预训练模型的方法进行实验改进; 并基于知识蒸馏法深入推进模型加速研究。实验表明, 通过联合训练能够提升模型的泛化能力与特征提取能力, 进而增强特定任务下的学习能力; 学生模型 TextCNN 经蒸馏后不仅可与教师模型相媲美, 在线上部署时还更具优势。

关键词: 短文本分类; 深度学习; 预训练模型; 辅助任务; 知识蒸馏

中图分类号: TP 391 **文献标志码:** A

A Chinese short text classification algorithm based on auxiliary tasks and knowledge distillation

CHEN Hao, JIN Guangxing, SU Hang

(School of Computer Science, Hubei University, Wuhan 430062, China)

Abstract: Short text categorization is a current hot research area. Pre-trained models perform well in this area, but they have problems such as data representation scattering and transfer learning limitations, which reduce the classification effect. Although large models such as ERNIE(enhanced representation through knowledge integration) improve the classification effect, they are difficult to be used in industrial production due to the problems of slow speed, high resource requirements, and hardware limitations. For this purpose, an ERNIE-based auxiliary task model EL(ERNIE+LAT(learning with auxiliary tasks)) model is proposed, with the aim of verifying its feasibility of obtaining better category features. In response to the requirements for the implementation of industrial tasks, a knowledge distillation method is proposed to conduct distillation training of the EL and TextCNN models to verify the classification effect as well as the feasibility of online reasoning efficiency improvement. Firstly, the classification advantages of the existing pre-trained models on public datasets are verified. Secondly, the experimental improvement is carried out by using the method of combining

收稿日期: 2024-07-08

作者简介: 陈昊(1977-), 男, 博士, 教授, 主要从事人工智能和智能计算研究, E-mail: ch@hubu.edu.cn。

通信作者: 苏航(1999-), 男, 硕士研究生, 主要从事人工智能、自然语言处理研究, E-mail: 2057988118@qq.com。

基金项目: 国家自然科学基金项目(编号: 61977021); 湖北省重点研发计划项目(重点项目)(编号: 2022BAA044); 湖北省技术创新专项(重大项目)(编号: 2019ACA144); 湖北省重点实验室开放基金(编号: 2020SDSJ06)。



本文引用格式: 陈昊, 金广星, 苏航. 基于辅助任务与知识蒸馏的中文短文本分类算法[J]. 武汉大学学报(工学版), 2026, 59(2): 308-318.

Citation: CHEN Hao, JIN Guangxing, SU Hang. A Chinese short text classification algorithm based on auxiliary tasks and knowledge distillation[J]. Engineering Journal of Wuhan University, 2026, 59(2): 308-318.

auxiliary tasks with the pre-trained models. Finally, the research of model acceleration is further advanced based on the knowledge distillation method. The experiments prove that the generalization ability and feature extraction ability of the model can be enhanced by joint training, thereby improving the learning ability in specific tasks. The student model TextCNN, after distillation, not only can rival the teacher model but also has more advantages when deployed online.

Key words: short text classification; deep learning; pre-trained model; auxiliary task; knowledge distillation

随着文本信息的爆炸式增长,文本数据分类已成为自然语言处理领域的一个重要课题^[1]。长文本分类取得了显著进展,但对于相对较短的文本,如新闻和评论等,其分类技术还不够成熟。短文本通常只包含几个词或句子,难以精确表达语义^[2]。在传统的文本分类模型中,通常需要手动提取特征或使用一些规则来处理短文本。此外,在中文短文本分类中,由于数据量相对较小,往往会出现数据稀疏的问题^[3],这些因素均制约短文本分类的发展^[4]。因此,需要开展更多研究以改进短文本分类。

在短文本分类这一自然语言处理(natural language processing, NLP)的关键领域,近年来学术界和工业界均见证了技术的显著进步与多样化发展。ZHOU等^[5]在NLP任务中采用了长短期记忆(long short-term memory, LSTM)网络,该网络因擅长处理长序列数据并捕捉序列间的长期依赖关系,在NLP任务中占据了一席之地。然而,LSTM模型存在固有的高复杂度、易过拟合以及对噪声敏感等问题,限制了其在实际应用中的广泛性和准确性。为克服这些挑战,研究者们不断探索新的模型架构,以期在保持模型性能的同时降低计算成本并提高鲁棒性。万圣贤等^[6]提出了局部化双向LSTM模型,该模型通过聚焦于局部上下文信息,有效提升了长序列建模的能力,并缓解了梯度消失与梯度爆炸的难题。通过灵活的网络结构配置,该模型能够适配不同长度的输入序列,增强了模型的适应性和灵活性。然而,尽管有所改进,双向LSTM模型依然面临计算效率不高和对噪声敏感的问题,限制了其在实际应用中的进一步推广。为进一步提升短文本分类的准确性和效率,LAI等^[7]引入了循环卷积神经网络(region-based convolutional neural networks, RCNN)。RCNN结合了卷积神经网络(convolutional neural networks, CNN)在特征提取上的高效性和循环神经网络(recurrent neural network, RNN)在序列建模上的优势,通过在序列的每个位置上进行卷积和池化操作,有效捕捉了文本中的关键特征,并利用RNN对序列信息进行建模,从而显

著提高了分类的准确度。然而,RCNN模型在特征提取过程中的计算量较大,且模型的可解释性相对较弱,同时在处理不同长度文本时存在挑战。

随着注意力机制^[8]的提出,研究表明只需关注少量关键特征即可实现相同任务效果^[9]。NLP领域迎来了新的变革:VASWANI等提出的Transformer模型,通过自注意力结构(self-attention)^[10]颠覆了传统的RNN网络结构,实现了对序列中每个位置重要性的精准计算,从而高效提取特征。Transformer模型不仅提高了模型的性能,还通过并行计算大幅加速了训练和推理过程^[11]。随后,BERT (bidirectional encoder representations from transformers)的提出^[12],更是将预训练模型推向了新的高度,为NLP任务提供了强大的性能支持。然而,尽管BERT等预训练模型在英文文本处理上取得了显著成效,但在中文短文本分类领域的应用相对较少。百度提出的ERNIE(enhanced representation through knowledge integration)模型^[13]通过引入知识增强策略,为中文文本处理提供了新的思路^[14]。基于ERNIE的中文文本分类方法,通过生成具有丰富上下文信息的词向量,显著提升了分类效果。廖梦等^[15]提出在多标签文本分类任务中采用双仿射机制进行解码预测,2个任务共享除解码层以外的所有参数,保证了不同的监督信息反馈到每个子任务。尽管廖梦等人的方法在中文文本分类上取得了显著成效,但模型在处理大规模数据集时可能面临计算资源消耗过大的问题。同时,对于某些特定领域的文本分类任务,可能需要进一步调整模型结构和参数以优化性能。BERT、ERNIE等预训练模型同样存在一些缺陷。例如,鉴于不同阶段的语料库数据表征散布、fine-tuning任务单一性等问题,这些预训练模型偏离真实语义,进而降低分类效果;此外,模型本身参数量过大、依赖于硬件以及线上推理时延高等问题也较为突出。但是相较于传统的深度学习方法,预训练模型仍然展现出更强的泛化与特征提取能力,因此将其应用于短文本分类仍是当前学者的主流研究方向。目前,NLP

任务在工业领域备受关注,将知识与经济效益相结合是实现科学成果落地的必要途径^[16]。尽管高精度模型不断涌现,如预训练模型推动了自然语言处理任务,但由于其结构复杂、占用较大的存储空间以及计算代价过于昂贵等问题,使得在线部署十分依赖于硬件环境,且难以达到可接受的分析时延,从而影响了工业任务的落地。传统机器学习和深度学习算法虽适合快速部署,但会牺牲高精度。科学理论必须与实际相结合,才能转化为具有经济效益的工业产品,否则这些理论失去了在工业中的应用前景。针对以上问题,本文以提高短文本分类精度为递进脉络,首先探究验证现有的预训练模型在公共数据集上的分类优势,其次采用辅助任务结合预训练模型的方法避免预训练模型的训练噪声,并且基于主流模型加速法——知识蒸馏法^[17],渐次深入地推进对模型压缩加速的研究,随后对所得数据进行实证分析。即验证科学理论只有联系实际才能转化成产品的思想,在考虑投入产出比的工业生产中,基于辅助任务和知识蒸馏的理论,通过引入预训练模型进行实验的对比分析,证实短文本分类结果提升的假设,并且该方法可用于解决文本分类任务中知识与经济效益相结合落地应用的问题。

1 结合辅助任务学习和 ERNIE 的短文本分类方法

针对提高短文本分类精度这一任务,本文在 ERNIE 预训练模型的基础上,采用辅助任务学习 (learning with auxiliary tasks, LAT)^[18] 结合预训练模型的方法进行实验改进。该方法的原理为一种

归纳迁移的学习方式,模拟人类根据一些常识经验或先验认知学习新目标任务的过程,通过多个任务之间的参数共享,削弱模型对于单一任务的学习能力,从而降低网络过拟合的可能性;通过在不同任务的训练过程中实现动态的信息平衡,提升模型的泛化能力与特征提取能力,进而使模型学习到更通用的类别特征知识。基于此,本文提出了一种基于辅助任务的短文本分类模型,这里将其称为 EL (ERNIE+LAT) 模型。联合训练模型的网络架构如图 1 所示。其中,ERNIE 作为一种动态的知识表征模型,能够有效弥补静态词向量表征的语义不完整问题,擅长捕捉知识语义中的潜在信息继而在 ERNIE 上构建多任务间的共享层。此外,辅助任务与主任务之间应具有一定的相关性,任务之间共享信息可以相互补充,提升彼此的表现,使得主任务可以学习到更好的类别特征,从而帮助模型捕捉到共享层的特征信息。

1.1 ERNIE 预训练模型

ERNIE 编码器的多层 Transformer 架构是堆叠式的,即每一层的输出都作为下一层的输入,这种结构可以增加模型的深度,提高模型的性能。Add-Norm 层是 Transformer 模型中的一种标准层,它包含 2 个步骤:在 Addition 步骤中,模型将输入与残差连接的输入相加;在 Normalization 步骤中,模型将加法结果归一化,以更好地处理梯度消失和爆炸问题,并提高模型的稳定性和收敛速度。Norm 层即归一化层,负责对输入和输出进行归一化操作,计算结果会进入前馈神经网络层,之后循环进入下一个残差连接和归一化层,进行同等的计算变换,最终得到归一化的词向量列表。




图1 EL联合训练模型架构

Fig.1 Architecture of the EL joint training model

假使输入词序列为 $w_{i-(n-1)}, \dots, w_{i-1}$, 在此过程中,顺序拼接词序列中的每个词向量,最终形成 ER-

NIE 输入层的结果 X :

$$X = [E(w_{i-(n-1)}), \dots, E(w_{i-2}), E(w_{i-1})] \quad (1)$$

式中: E 为词向量映射函数,用于将离散的词符号映射为高维稠密向量; w 为输入序列中的词; X 为模型输入层的最终向量表示。

1.2 辅助任务

辅助任务学习也称作多任务学习(multi-task

learning, MTL)^[19]。其与单任务学习的区别如图2所示:单任务学习旨在解决一个特定的任务,例如图像分类或自然语言处理,而辅助任务学习则旨在同时解决多个相关任务。虽然这2种方法都可用于解决实际问题,但它们的原理和方法有所不同^[20]。




图2 单任务学习与辅助任务学习的区别

Fig.2 Difference between single-task learning and auxiliary-task learning

在辅助任务学习中,一个模型被设计为同时处理多个输入和输出,进而学习多个任务之间的关系和共享信息^[21]。这种方法可有效减少学习时间和资源消耗,同时提高模型的表现能力^[22]。若2个任务之间存在相关性,那么它们可能共享一些相同的特征,从而能够共同学习。例如,人脸识别和情感分类这2个任务都需要对图像进行分类,因此它们可以共享卷积层的特征提取器。此外,多任务学习可以通过在模型中引入共享参数来降低模型的复杂性。

1.3 辅助任务损失函数

本文在子任务间采用参数硬共享的模式,即由共享参数层进入子任务各自的分类模型,进行标签预测。对于同类短文本判别与短文本分类这2个任务的损失函数本文采用叠加的方式处理。考虑到不同任务难易程度和学习速度存在差异,可以针对不同任务设置不同学习率,但更好的思路是通过动态调整,让各个任务以相近的速度学习。因此,本文对单任务的损失函数 Loss 采用动态加权平均的方式进行联合计算,公式如下:

$$\text{Loss} = \sum_{i=1}^K w_i(t) \times \text{loss}_i \quad (2)$$

式中: loss_i 为不同任务的损失值; $w_i(t)$ 为每个任务 i 的权重; t 为模型训练过程中的步数。 $w_i(t)$ 的计算如下式:

$$w_i(t) = \frac{K \exp\left(\frac{r_i(t-1)}{Q}\right)}{\sum_{j=1}^K \exp\left(\frac{r_j(t-1)}{Q}\right)} \quad (3)$$

$$r_i(t-1) = \frac{\text{loss}_i(t-1)}{\text{loss}_i(t-2)}, t \geq 2 \quad (4)$$

式(3)~(4)中: Q 为一个常数,当 $Q=1$ 时, w 相当于一次 Softmax 的结果;若 Q 足够大,则 w 趋近于1,这意味各个任务的损失权重相同。因此,对于损失降低慢的任务,其权重会变得更大。 K 为任务数,由于加入了辅助任务与主任务,故 K 值为2; $\text{loss}_i(t-1)$ 为任务 i 在第 $t-1$ 步时的损失结果; $r_i(t-1)$ 表示训练的速度。

1.4 辅助任务构造

在多任务学习中,任务的构造是一个重要的问题,需要考虑任务的相关性、难度和输入输出等方面。构造具有相关性、难度不同且输入输出不同的任务,并适当控制任务数量,有助于提高模型的泛化能力和效率^[23]。本文采用清华大学 THUCNews 开源大型新闻语料库进行实验,实验包括新闻标题分类这一主任务以及一个辅助任务:判别2个新闻标题是否属于同类别新闻。鉴于主辅任务的相关性,本文在原有数据集上构建同类和异类的新闻标题语句对作为输入序列,进行辅助任务与主任务的联合训练,从而达到多任务学习效果,即某个任务中包含对另一个任务有用的信息时,可提高在后者任务上的表现,进而帮助 ERNIE 模型捕捉到更优的类别特征信息,更完善地完成新闻标题多分类任务的学习。

2 基于知识蒸馏的融合 ERNIE 模型

在深度学习领域,各种技术正蓬勃发展。然

而,复杂模型通常需要大量的计算资源,如内存、GPU(graphics processing unit)等。获取这些资源需要大量投入,由此导致的高昂成本在工业应用中难以被接受。因此,模型压缩成为必要手段,其中知识蒸馏作为一项重要技术^[24],近年来呈现出蓬勃发展态势^[25]。知识蒸馏是一种模型加速技术^[26],其核心思想是利用一个小模型学习一个大模型的知识,

将大模型的知识压缩到小模型中,以实现加速小模型的训练和推理^[27],达到简化模型部署的目的。

知识蒸馏可分为 2 个阶段:第 1 阶段是训练一个教师模型,以获得更精准的预测结果;第 2 阶段是训练一个学生模型,并使用教师模型的输出作为标签来训练学生模型,以获取更好的泛化性能。具体过程如图 3 所示。




图 3 知识蒸馏学习过程

Fig.3 The learning process of knowledge distillation

首先,训练一个教师模型,由于对教师模型线上推理的速度没有要求,其主要目标是提升学生模型的准确率,因此,本文采用前文提出的 EL 模型作为教师模型。教师模型通常是一种大而深的模型,也可通过多个模型集成来构建。

其次,构建结构相对简单的学生模型,使其学习教师模型学到的知识,即选择一个轻量级的小模型。

然后,最重要的一步是设计知识蒸馏模型的损失函数,以此来训练学生模型。知识蒸馏模型的 Loss 函数定义如下:

$$\text{Loss} = \alpha L_{\text{soft}} + (1 - \alpha) L_{\text{hard}} \quad (5)$$

式中: L_{soft} 为教师模型根据软标签“教授”学生模型的损失函数; L_{hard} 为学生模型依据硬标签计算的损失; α 和 $(1 - \alpha)$ 分别代表各自的权重,在学生模型的蒸馏过程中,会不断修正 α 和 $(1 - \alpha)$ 的取值。与此同时,依据学生模型与硬标签以及教师模型之间的 Loss 函数进行计算,赋以权重后进行相加操作,最后应用反向传播算法更新模型参数。蒸馏损失函数 L_{soft} 的具体含义如下:

$$L_{\text{soft}} = - \sum_{i=1}^N p_i \log(q_i) \quad (6)$$

$$p_i = \frac{\exp(\frac{v_i}{T})}{\sum_{k=1}^N \exp(\frac{v_k}{T})} \quad (7)$$

$$q_i = \frac{\exp(\frac{z_i}{T})}{\sum_{k=1}^N \exp(\frac{z_k}{T})} \quad (8)$$

式(6)~(8)中: p_i 为教师模型的输出结果,将其作为学生模型学习的目标; N 为分类任务的总类别数; k 为类别索引; v_i 与 v_k 为教师模型对第 i 或第 k 个任务类别的原始输出 logits; z_i 与 z_k 为学生模型(TextCNN)在 Softmax 层之前的原始输出值(logits (其作为一种表示概率输出的方法,是深度神经网络模型中未经归一化处理的值,得出属于各个类别的汇总分值 z_i)), 对应于教师模型的输出 v_i 。通过计算教师模型与学生模型的交叉熵,使学生模型的输出结果 q_i 尽可能接近 p_i 。温度参数 T 是一个重要的超参数,它控制着传递知识的“软化程度”,影响着学生模型的训练效果和性能^[28]。知识蒸馏法中的温度参数是一个正实数,通常取值在 1 到 10 之间,用来调整教师模型输出的概率分布的“软化程度”。在传递知识的过程中,教师模型的输出概率分布通常比较“尖锐”,即某些类别的概率非常接近

于0或1,这样的输出很难让学生模型进行有效的学习。因此,本文需要增加温度参数,例如,当 T 越大时,会使各个类别输出的概率分布相对平滑,一定程度上保留各个类别之间的隐藏知识。

对于本文的分类问题, L_{hard} 可通过交叉熵进行计算。具体计算公式如下:

$$L_{\text{hard}} = - \sum_{j=1}^N c^j \log(q_i) \quad (9)$$

$$q_i = \frac{\exp(\frac{z_i}{T})}{\sum_{k=1}^N \exp(\frac{z_k}{T})} \quad (10)$$

式(9)~(10)中: c^j 为样本的真实标签,对于分类问题,其值为0或1。Softmax的计算在网络的logits结果 z_i 上进行,经过Softmax计算后得到的概率分布会放大logits,使类目之间的差异增大。因此在知识蒸馏中,通常在logits的基础上添加一个温度变量 T ,对logits结果进行缩放,当 $T=1$ 时,为正常输出。

最后,使用学生模型进行线上预测,且注意此时需将 T 设置为1。

3 实验与结果分析

3.1 实验数据与环境

在自然语言处理中,短文本一般指长度较短、信息量有限的文本,如新闻标题、微博、推文等。由于新闻标题具有信息密度高、词数少的特点,通常也被归类为短文本。因此,选择使用新闻标题作为短文本分类任务的数据集是较为合理的。在短文本分类任务中,需要采用更加细致、精准的特征提取方法和分类模型,同时需要增加训练数据并优化模型,以提高分类的准确度和泛化能力^[29]。本文选取2个数据集:1)THUCNews标题数据集;2)THUCNews新闻数据集。采用正采样与负采样的方式获取训练集:正采样为随机从同一类别标题中抽取其他标题数据,以构造同类标题语句对;负采样为以相同概率从不同类别标题中选取新闻标题,以构建异类标题语句对。

对于句子对输入的任务(如本文辅助任务),输入数据格式为2个句子。每个句子通过WordPiece tokenizer进行分词,并添加特殊标记符[CLS]和[SEP]。2个句子之间添加一个特定的分隔符[SEP],作为2个句子的分界线。例如,对于体育类标题“西班牙寻仇却险些再被逼下山崖不靠裁判韩国一样难啃”和教育类标题“英国实施记点积分新政申请签证更便捷”这两句话,构成不同类新闻标

题语句对,经过分词和添加特殊标记符后,可以得到输入序列:“[CLS]西班牙寻仇却险些再被逼下山崖不靠裁判韩国一样难啃[SEP]英国实施记点积分新政申请签证更便捷[SEP]”。实验环境参数如表1所示。

表1 实验环境参数

实验环境	版本/型号
操作系统	Ubuntu 18.04
GPU	RTX 3090 24G
CPU	Inter(R) Platinum 8358P
编程语言	Python 3.8
开发框架	Pytorch 1.9.0
CUDA 版本	11.1

3.2 辅助任务参数

辅助任务实验超参数如下:批量大小设置为64,训练轮数设置为10,使用Adam优化器,学习率设为 2×10^{-5} ,提前终止轮数为连续3个训练轮数,并依据验证集效果进行调优。

3.3 知识蒸馏参数

1)温度参数:当 $T=1$ 时,其与普通的Softmax输出一致;当 $T>1$ 时,Softmax后的值分布会更加均匀、平缓;当 $T<1$ 时,Softmax取值后会变得更加陡峭。因为 T 值较大时,各个值都会变得平均,负标签显著变大,此时学生模型对负标签的关注度也会增大。反之,当 T 值较小时,负标签会变得更小,学生模型对于负标签的关注也会减少。而本文的目标是通过知识蒸馏使学生模型学到更多的知识,包括教师模型中包含的“暗知识”,所以负标签中的信息也尤为重要,故将温度设置稍大为5。

2)平衡参数 α 选为0.5。

3.4 实验评价指标

本文使用准确率(accuracy)、精确率(precision)、召回率(recall)和 F_1 值(F_1 _Score)4个指标来评估模型的分类效果。各指标计算公式如下:

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN} \quad (11)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (12)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (13)$$

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (14)$$

式(11)~(13)中:TP(true positive)表示真阳性样本数,即被模型正确预测为正类的样本数量;TN(true

negative)表示真阴性样本数,即被模型正确预测为负类的样本数量;FP(false positive)表示假阳性样本数,即负类被模型错误预测为正类的样本数量;FN(false negative)表示假阴性样本数,即正类被模型错误预测为负类的样本数量。

3.5 辅助任务实验结果及分析

本文采用 THUCNews 新闻数据集,该语料库共包含 74×10^4 条新闻文本,其中训练集有 63×10^4 条,测试集有 11×10^4 条。使用前需对语料库进行预处理,包括去除噪声数据、选取类别以及抽取标题等步骤。预处理后得到 10 种新闻类别的标题数据集,各类别抽取样本数据情况如表 2 所示。为平衡每个类别的数据量,避免因数据不均衡带来训练噪声,对每种类别均匀抽取 2×10^4 条数据,并按照 8:1:1 的比例分别设置训练集、验证集与测试集。

表 2 THUCNews 样本数据	
Table 2 Sample data of THUCNews	
新闻标题短文本	类别
普天称已研发出 TD 无线城市应用方案	科技
轿车闹市失控撞伤 7 名路人(图)	社会
拉姆:德国队年轻但不可小视 克洛泽:从没怀疑过自己	体育
MySpace 创始人 与 希尔顿神秘约会(图)	娱乐
香港破产亿万富豪凭信心翻身:曾一夜失去 11 亿	股票
解密:西方人为何如此恐惧数字“13”	教育
“有你的”企业魔兽联赛八强选手名单	游戏
黎巴嫩防空部队向进入领空以色列战机开火(图)	政治
格拉斯小镇游船起航暨美术馆揭牌仪式(组图)	房地产
价格太高 中国连续两周未进口美国大豆	金融

模型训练完成后,在测试集上完成验证。如表 3 所示,使用 ERNIE 模型 的分类准确率为 94.57%,EL 模型 的分类准确率为 95.83%,实验结果证明 EL 模型确实提升了准确率。

表 3 ERNIE 和 EL 实验准确率结果	
Table 3 Accuracy results of ERNIE and EL experiments	
模型	准确率/%
ERNIE	94.57
EL	95.83

表 4 为 ERNIE 模型和 EL 模型在各新闻标题类别上的指标值对比。由表中结果可知,EL 模型在绝大多数类别上的 F_1 值均高于直接使用 ERNIE 模型进行新闻标题分类的测试效果。

实验结果表明,加入了辅助任务并结合主分类任务的联合训练,能够显著提高 ERNIE 模型 的分类

表 4 ERNIE 和 EL 模型在各类别上的精确率、召回率和 F_1 值

Table 4 Precision, recall, and F_1 values of the ERNIE and EL models in various categories

类别	精确率/%		召回率/%		F_1 值	
	ERNIE	EL	ERNIE	EL	ERNIE	EL
娱乐	94.68	94.96	97.80	98.00	96.21	96.46
游戏	97.34	98.06	95.00	95.90	96.16	96.97
体育	98.60	99.09	98.60	98.80	98.60	98.64
政治	90.63	92.48	93.80	94.20	92.19	92.34
社会	95.75	95.85	92.30	96.10	93.99	94.03
科技	93.35	93.73	89.90	92.10	91.59	91.91
教育	96.34	97.96	97.40	95.80	96.87	96.87
股票	90.66	92.55	91.20	91.70	90.93	91.62
房地产	92.31	95.96	97.20	97.00	94.69	95.48
金融	96.04	95.12	92.10	93.60	94.03	94.35

效果。具体而言,由表 3 可知,EL 模型 的准确率较 ERNIE 模型提高了 1.26%;由表 4 的对比可知,EL 模型在多个新闻标题类别上的表现优于 ERNIE 模型。

依据异常预测样本,本文发现预测类别与标签不匹配。经分析可知:大部分此类样本标题的相似点在于其所属标题类别更为复杂抽象,蕴含了多类别的信息。表 5 列举了部分分类异常样例。例如,“寒门铁克同意收购安全软件商 Giden”,这一标题既可能属于股票类新闻,也可能属于科技类新闻,但模型预测为科技类新闻,而原标签是股票类。又如“网戒中心电击治网瘾”这一标题涉及游戏与社会 2 个领域。虽然标题提到的是“网戒中心”,但其内容涉及社会问题(如网瘾),模型将其归类为社会类。

表 5 分类错误样本

分类错误样本	原标签	预测标签
网戒中心电击治网瘾:违反 86 条规定者即遭电击	游戏	社会
湖南长沙 140 平方米景观房 7 天涨价 50 万元	社会	房地产
寒门铁克同意收购安全软件商 Giden	股票	科技
五部委联推工矿棚户区改造	房地产	政治

对于上述问题,在实验过程中不仅要考虑模型 的 Top-1 准确率,还应将 Top-2 准确率和 Top-3 准确率考虑在内。表 6 显示,EL 模型 的这 3 项准确率均高于 ERNIE 模型。此结果充分说明,辅助任务确实减少了预训练模型训练过程中的噪声,即通过模拟人类根据一些常识经验或先验认知学习新目标

任务的过程,去权衡不同目标任务的训练信息,进而提升模型泛化、特征提取能力,使模型能够学习到更通用的类别特征知识。

表 6 ERNIE 与 EL 的准确率结果
Table 6 Accuracy results of ERNIE and EL

模型	准确率/%		
	Top-1	Top-2	Top-3
ERNIE	94.57	95.30	96.26
EL	95.83	96.43	97.47

3.6 对比实验及结果分析

为验证预训练模型在新闻标题分类任务中的优势,本文在相同实验环境下,将预训练模型与传统的分类模型进行了实验对比。具体基线模型如下:

1)TextCNN:该模型将文本转化为定长的词向量序列,通过卷积神经网络提取文本的局部特征,最后使用全连接层将特征映射到分类结果。

2)TextRNN:该模型通过 RNN 对文本序列进行建模,捕捉文本序列的长期依赖关系,实现对整个序列的有效处理。

3)TextRNN_Att:该模型结合 RNN 与注意力机制,后者对文本序列中的重要信息进行加权,通过考虑上下文信息,更准确地捕捉文本序列中的重要信息。

4)BERT_CNN:该模型将 BERT 作为 Embedding 层,接入含有 3 种卷积核的 CNN,BERT_CNN 结合了 BERT 和 TextCNN 的优点。

5)BERT_RCNN:该模型将 BERT 作为 Embedding 层,通过 LSTM 的输出与 BERT 的输出进行拼接,再经过一层最大池化层。

6)ERNIE_TextCNN:该模型将 ERNIE 作为 Embedding 层,接入含有 3 种卷积核的 CNN 进行融合训练。

对比实验采用的数据集已在本文 3.5 节中进行了阐述。对比实验的部分参数设置如表 7 所示,实验结果如表 8 所示。对比实验中采用 Adam 优化器,GPU 加速为 True。

由表 8 可知,由于传统文本方法存在劣势,将预训练模型应用于新闻标题短文本分类能够显著提升准确率。本文算法 EL 在精确度上均优于对比模型。与 TextCNN、TextRNN、TextRNN_Att、BERT_CNN、BERT_DPCNN 和 ERNIE_TextCNN 模型相比,本文算法的精确度分别提升了 4.77%、

表 7 对比实验部分参数设置
Table 7 Partial parameter setting for the comparative experiment

参数	数值
学习率	2×10^{-5}
总参数大小/Mb	110
隐藏层层数	768
最大序列长度	128
每批次训练样本个数	64
迭代次数	5

表 8 各模型准确率实验结果
Table 8 Experimental results of model accuracy rates

模型	准确率/%
TextCNN	91.06
TextRNN	90.94
TextRNN_Att	90.60
BERT_CNN	94.18
BERT_DPCNN	93.33
ERNIE_TextCNN	94.02
ERNIE	94.57
EL	95.83

4.89%、5.23%、1.65%、2.5%、1.81%。

3.7 知识蒸馏任务结果及分析

3.7.1 新闻短文本分类任务分析

本文采用 THUCNews 标题数据集,该数据集包含 10 个类别,即娱乐、游戏、运动、政治、社会、科技、教育、股票、房地产和金融。每个类别包含 20 000 条数据,按照每类 9:2:1 的比例分配训练集、测试集和验证集进行实验。为明确指代,本文将基于知识蒸馏策略、由教师模型 EL 指导训练得到的学生模型 TextCNN 统称为 EL-TextCNN 蒸馏模型。实验结果如表 9 所示。

表 9 知识蒸馏各模型准确率
Table 9 Accuracy results of each model in knowledge distillation

模型	准确率/%
教师模型 EL	95.83
学生模型 TextCNN	92.07
EL-TextCNN 蒸馏模型	95.65

由表 9 可知,教师模型 EL 的准确率达到 95.83%;轻量级的学生模型 TextCNN 由于结构较为简单,仅通过超参数的优化,其准确率只能达到 92.07%。因此,教师模型 EL 凭借其复杂的网络结构与网络特性,具备更强的特征提取及泛化能力,

在相同数据集下获得了更好的结果。在EL的知识蒸馏下,EL-TextCNN蒸馏模型的准确率可达到95.65%,相较于单纯使用TextCNN,效果提升了3.58%。

由表10可知,基线模型如BERT_DPCNN、ERNIE_TextCNN等在准确率方面表现较好,但仍低于EL-TextCNN蒸馏模型。例如,BERT_DPCNN的准确率为93.33%,而EL-TextCNN蒸馏模型在相似任务上的准确率达到95.65%,接近于教师模型的95.83%。这表明EL-TextCNN蒸馏模型不仅能够保持较高准确率,还可简化模型结构。

表 10 蒸馏模型与基线模型准确率对比
Table 10 Comparison of accuracy rates between distillation model and baseline model

模型	准确率/%
BERT_DPCNN	93.33
ERNIE_TextCNN	94.02
EL-TextCNN蒸馏模型	95.65

为探究学生模型文本分类结果的精度损失问题,本文对10个新闻类别上的分类结果进行分析,结果如图4所示。




图 4 TextCNN、EL、EL-TextCNN 蒸馏模型在 10 种类别上的准确率对比

Fig. 4 Comparison of accuracy rates of TextCNN, EL, and EL-TextCNN knowledge distillation model on ten categories

由图4可知,蒸馏后的学生模型在大多数的类别下都与教师模型的结果相差不多,且其文本分类效果均优于单纯的学生模型。尤其是在政治、房地产、金融这些类别上,与教师模型基本一致。由此可知,学生模型作为知识的接收者,会吸收老师模型传递的知识,因为最终学生模型输出的概率分布不仅要拟合教师模型的soft target,还需要拟合样本真正的标签,即hard target。所以学生模型不仅局

限于自身学习,还学习到了教师模型中深层的知识。然而,受限於学生模型TextCNN自身结构的单一性与网络性质,经过蒸馏后的模型效果仍无法超过教师模型。但总体而言,当工业生产落地抛弃大模型的复杂度,选择知识蒸馏轻量模型进行上线部署以及低时延分析时,该轻量模型分类精度的少量损失,符合工业生产落地中的经济效益要求。

3.7.2 推理时间分析

为实现文本分类任务的有效落地部署与上线分析,需要验证知识蒸馏后的模型是否符合要求。因此,本文在相同的测试数据集下对教师模型以及蒸馏模型进行参数量以及平均推理时间的对比,对比结果如表11所示。

表 11 教师模型与蒸馏模型推理时间和参数量对比
Table 11 Comparison of inference time and number of parameters between teacher model and distillation model

模型	平均推理时间/s	参数量($\times 10^6$)
教师模型EL	2.65	104
EL-TextCNN蒸馏模型	0.13	38

由表11可知,EL-TextCNN蒸馏模型的参数量远少于教师模型,模型复杂度较低,加上蒸馏的作用,其上线推理时间约为教师模型的1/20。尽管EL-TextCNN蒸馏模型的准确率相较于教师模型略有下降,但其在推理时间和模型复杂度上的优势,使其更适用于实际应用场景。特别是在移动端或实时系统中,低延迟的推理时间与较低的硬件需求至关重要。此外,EL-TextCNN蒸馏模型的准确率仍接近教师模型,这表明其在知识传递和模型压缩方面具有有效性。精度上的略微损失换来了实际应用场景中更广阔的收益。

4 结束语

本文旨在研究短文本分类任务在工业生产中的有效落地,以达到科学理论联系实际的目的,这对于将知识转化为经济效益具有重要意义。首先,针对预训练模型的缺陷,本文引入辅助学习思想,构造EL模型,以降低预训练过程中带来的训练噪声;其次,为解决短文本分类任务在工业上的有效落地问题,本文引入知识蒸馏概念,构造教师-学生模型,验证模型加速的可行性。虽然本文在解决分类任务及模型部署上线方面取得了一些优势,但仍然存在若干需要改进与加强的地方,有待后续研究:

1)针对辅助任务的选取。在辅助任务学习中,

任务的构造是一个重要问题,需要考虑任务的相关性、难度以及输入输出等方面。构造具有相关性、难度不同且输入输出不同的任务,并适当控制任务数量,有助于提高模型的泛化能力和效率。本文基于一项任务假设,仅选取了一个相关任务。但辅助任务的思想在于训练过程的结果倾向于得到在多个任务上具有较高泛化能力的解。因此,在后续研究中可以引入多个辅助任务,规范辅助任务与主任务的相关性,丰富理论背景。

2)针对模型加速法的选取。本文基于文本分类任务的工业落地需求,结合模型分类效果及模型特点,选取知识蒸馏法进行模型加速。目前,大多数项目因模型网络对硬件存在依赖性仅停留在实验室阶段,而模型加速法已形成一套理论体系,其中网络剪枝、张量分解、权重量化等方法也颇为成熟。因此,后续研究可基于这些理论方法开展实践,以推动文本分类任务的有效落地。

参考文献:

- [1] 李博涵,向宇轩,封顶,等.融合知识感知与双重注意力的短文本分类模型[J].软件学报,2022,33(10):3565-3581.
LI Bohan, XIANG Yuxuan, FENG Ding, et al. Short text classification model combining knowledge aware and dual attention[J]. Journal of Software, 2022, 33(10): 3565-3581.
- [2] 李志明,孙艳,何宜昊,等.融合类别特征扩展与N-gram子词过滤的fastText短文本分类[J].小型微型计算机系统,2022,43(8):1596-1601.
LI Zhiming, SUN Yan, HE Yihao, et al. Short text classification with category feature expansion and N-gram subword filtration based on fastText[J]. Journal of Chinese Computer Systems, 2022, 43(8): 1596-1601.
- [3] 王俊丽,杨亚星,王小敏.短文本分类的ResLCNN模型[J].软件学报,2017,28(s2):61-69.
WANG Junli, YANG Yaxing, WANG Xiaomin. ResLCNN model for short text classification[J]. Journal of Software, 2017, 28(s2): 61-69.
- [4] XU J Y, CAI Y, WU X, et al. Incorporating context-relevant concepts into convolutional neural networks for short text classification[J]. Neurocomputing, 2020, 386: 42-53.
- [5] ZHOU P, SHI W, TIAN J, et al. Attention-based bidirectional long short-term memory networks for relation classification[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, 2016: 207-212.
- [6] 万圣贤,兰艳艳,郭嘉丰,等.用于文本分类的局部化双向长短时记忆[J].中文信息学报,2017,31(3):62-68.
WAN Shengxian, LAN Yanyan, GUO Jiafeng, et al. Local bidirectional long short term memory for text classification[J]. Journal of Chinese Information Processing, 2017, 31(3): 62-68.
- [7] LAI S W, XU L H, LIU K, et al. Recurrent convolutional neural networks for text classification[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2015, 29(1):2267-2273.
- [8] ZHOU J, XU W. End-to-end learning of semantic role labeling using recurrent neural networks[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing, 2015: 1127-1137.
- [9] ZHOU X J, WAN X J, XIAO J G. Attention-based LSTM network for cross-lingual sentiment classification[C]//Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, 2016:247-256.
- [10] ZHAO H S, JIA J Y, KOLTUN V. Exploring self-attention for image recognition[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020: 10073-10082.
- [11] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//31st Annual Conference on Neural Information Processing Systems (NIPS), 2017: 5998-6008.
- [12] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics, 2019:4171-4186.
- [13] ZHANG Z Y, HAN X, LIU Z Y, et al. ERNIE: enhanced language representation with informative entities[EB/OL]. arXiv: 1905.07129[2024-06-08]. <https://arxiv.org/abs/1905.07129>.
- [14] SUN Y, WANG S H, LI Y K, et al. ERNIE: enhanced representation through knowledge integration [EB/OL]. arXiv:1904.09223[2024-06-08]. <https://arxiv.org/abs/1904.09223>.
- [15] 廖梦,贾真,李天瑞.基于标签信息融合与多任务学习的中文命名实体识别[J].计算机科学,2024,51(3):198-204.
LIAO Meng, JIA Zhen, LI Tianrui. Chinese named entity recognition based on label information fusion and multi-task learning[J]. Computer Science, 2024, 51(3):

- 198-204.
- [16] 何力, 郑灶贤, 项凤涛, 等. 基于深度学习的文本分类技术研究进展[J]. 计算机工程, 2021, 47(2): 1-11.
HE Li, ZHENG Zaoxian, XIANG Fengtao, et al. Research progress of text classification technology based on deep learning[J]. Computer Engineering, 2021, 47(2): 1-11.
- [17] 黄震华, 杨顺志, 林威, 等. 知识蒸馏研究综述[J]. 计算机学报, 2022, 45(3): 624-653.
HUANG Zhenhua, YANG Shunzhi, LIN Wei, et al. Knowledge distillation: a survey[J]. Chinese Journal of Computers, 2022, 45(3): 624-653.
- [18] CARUANA R. Multitask learning[J]. Machine Learning, 1997, 28(1): 41-75.
- [19] ZHANG Y, YANG Q. A survey on multi-task learning [J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(12): 5586-5609.
- [20] YU T H, KUMAR S, GUPTA A, et al. Gradient surgery for multi-task learning[EB/OL]. arXiv: 2001.06782. [2024-06-08]. <https://arxiv.org/abs/2001.06782>.
- [21] ZHANG Y, YANG Q. An overview of multi-task learning[J]. National Science Review, 2018, 5(1): 30-43.
- [22] 张钰, 刘建伟, 左信. 多任务学习[J]. 计算机学报, 2020, 43(7): 1340-1378.
ZHANG Yu, LIU Jianwei, ZUO Xin. Survey of multi-task learning[J]. Chinese Journal of Computers, 2020, 43(7): 1340-1378.
- [23] STANDLEY T, ZAMIR A, CHEN D, et al. Which tasks should be learned together in multi-task learning? [C]//Proceedings of the 37th International Conference on Machine Learning. 2020: 9120-9132.
- [24] PARK W, KIM D, LU Y, et al. Relational knowledge distillation[C]//Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:3967-3976.
- [25] 邵仁荣, 刘宇昂, 张伟, 等. 深度学习中知识蒸馏研究综述[J]. 计算机学报, 2022, 45(8): 1638-1673.
SHAO Renrong, LIU Yuang, ZHANG Wei, et al. A survey of knowledge distillation in deep learning[J]. Chinese Journal of Computers, 2022, 45(8): 1638-1673.
- [26] GOU J P, YU B S, MAYBANK S J, et al. Knowledge distillation: a survey[J]. International Journal of Computer Vision, 2021, 129(6): 1789-1819.
- [27] CHO J H, HARIHARAN B. On the efficacy of knowledge distillation[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019:4793-4801.
- [28] TANG J X, SHIVANNA R, ZHAO Z, et al. Understanding and improving knowledge distillation [EB/OL].arXiv:2002.03532[2024-06-08].<https://arxiv.org/abs/2002.03532>.
- [29] 孙昭颖, 刘功申. 面向短文本的神经网络聚类算法研究[J]. 计算机科学, 2018, 45(S1): 392-395.
SUN Zhaoying, LIU Gongshen. Research on neural network clustering algorithm for short text[J]. Computer Science, 2018, 45(S1): 392-395.

(编辑:高映月)