



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 融合知识图谱、ERNIE 与 TextCNN 的社科文献分类研究
作者: 韩卫红, 陈瑞鹏, 张可庆, 喇东升
网络首发日期: 2025-11-04
引用格式: 韩卫红, 陈瑞鹏, 张可庆, 喇东升. 融合知识图谱、ERNIE 与 TextCNN 的社科文献分类研究[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20251104.1502.012>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

融合知识图谱、ERNIE 与 TextCNN 的社科文献分类研究

韩卫红¹, 陈瑞鹏², 张可庆²⁺, 喇东升²

1. 东北大学秦皇岛分校 图书馆, 河北 秦皇岛 066004

2. 东北大学秦皇岛分校 计算机与通信工程学院, 河北 秦皇岛 066004

+ 通信作者 E-mail: 13171969237@163.com

摘要: 针对交叉学科动态性、海量文献复杂性及分类偏差问题, 研究提出融合知识图谱、ERNIE 预训练语言模型与 TextCNN 的文献学科分类模型 KG-ERNIE-TextCNN。通过整合知识图谱的语义增强技术、ERNIE 的深度语义编码机制及 TextCNN 的多尺度局部特征提取方法, 构建具有动态适应能力的学科分类框架。在包含 21 个一级学科的人文社科文献数据集上, 模型 F1 值达 77.46%, 较 BERT+TextCNN 提升 2.60%。消融实验表明, 知识图谱嵌入可使分类效果提升 1.04%, TextCNN 嵌入使分类效果提升 1.58%。针对学科交叉性导致的分类边界模糊问题, 通过构建专业领域知识图谱优化语义表征, 使交叉学科 F1 值平均提高 3.9%, 其中理论经济学与应用经济学交叉领域提升达 5.05%。实验结果表明, 专业学科领域知识增强方法可有效提升复杂学科分类性能。

关键词: 知识图谱; ERNIE 预训练模型; TextCNN; 文献学科分类; 交叉学科分析

文献标志码: A 中图分类号: TP391 doi: 10.3778/j.issn.1002-8331.2504-0167

Research on Social Science Literature Classification by Integrating Knowledge Graph, ERNIE and TextCNN

HAN Weihong¹, CHEN Ruipeng², ZHANG Keping²⁺, LA Dongsheng²

1. Library, Northeastern University at Qinhuangdao, Qinhuangdao, Hebei 066004, China

2. School of Computer and Communication Engineering, Northeastern University at Qinhuangdao, Qinhuangdao, Hebei 066004, China

Abstract: This study develops the KG-ERNIE-TextCNN fusion model to resolve Interdisciplinary dynamism and classified bias in academic literature. The model combines knowledge enhancement, ERNIE pre-training model, and TextCNN for multi-scale feature extraction. Evaluated on a 21-discipline humanities dataset, macro-F1 score reaches 77.46%, 2.60% higher than that of BERT-TextCNN. Ablation experiment shows that the knowledge graph embedding can improve the classified effect by 1.04% and TextCNN embedding can improve the classified effect by 1.58%. Aiming at the problem of fuzzy classified boundaries caused by interdisciplinary nature, semantic representation is optimized by constructing a knowledge map of professional fields. By doing so, the interdisciplinary value can be increased by 3.9% on average, including 5.05% in the interdisciplinary field of theoretical economics and applied economics. The experimental results show that the domain knowledge enhancement method can effectively improve the classified performance of complex disciplines.

基金项目: 中央高校基本科研业务费(N2023017)。

作者简介: 韩卫红(1981—), 女, 硕士, 馆员, 研究方向为科学计量与科学评价、数据挖掘与情报分析; 陈瑞鹏(2003—), 男, 本科生, 研究方向为自然语言处理、数据挖掘; 张可庆(2003—), 男, 本科生, 研究方向为自然语言处理、数据挖掘; 喇东升(1980—), 男, 博士, 副教授, 研究方向为机器学习、电磁场与微波技术。

Key words: knowledge graph; ERNIE pre-training model; TextCNN; literature classification; interdisciplinary analysis

随着“双一流”建设战略的持续深化,教育部一流学科的分类与评估已成为学术界及教育管理领域的核心议题。依据教育部相关文件(教研〔2020〕9号、13号)的指引,学科评估应围绕“质量、贡献、特色”三大维度展开,旨在优化现有评估体系,以契合高等教育高质量发展的需求。精准的学科分类作为“双一流”建设的基石,对于优化学科布局、科学配置资源以及提升国际竞争力具有举足轻重的意义。然而,当前学科分类体系正面临多重挑战。

学科交叉融合与新兴领域的动态演变成为了首要挑战。随着人工智能、生物信息等交叉学科的蓬勃兴起,传统单一学科框架已难以全面揭示其多元属性。现有分类体系往往将新兴学科简单归入某一单一学科,导致其在资源分配中遭受低估。据2023年《中国交叉学科发展报告》统计,超过40%的交叉学科文献因分类偏差而未能获得重点支持。

海量文献数据的复杂性问题亦不容忽视。近年来,文献规模呈指数级增长,且语义复杂性显著提升。以Web of Science为例,其年均新增文献量超过300万篇,传统分类方法在处理此类大规模、多主题数据时,易出现偏差或遗漏。例如,某高校图书馆2022年的抽样调查显示,基于传统方法的分类错误率高达28.7%,其中跨学科文献占比超过70%。

分类偏差所带来的负面影响不容小觑。分类不准确将导致新兴学科因未被识别而错失资金支持,进而抑制其发展潜力。研究人员依赖分类结果把握领域动态,偏差易导致研究方向偏离或重复研究。在国际评价体系中,学科分类是衡量学术影响力的重要依据。若分类体系滞后于学科发展,将削弱我国在国际学术合作中的话语权。

针对学科分类所面临的一系列挑战,本文提出了一种融合KG-ERNIE-TextCNN的文献学科分类模型。该模型融合了知识图谱的语义增强功能、知识增强的语义表示模型(Enhanced Representation through Knowledge Integration, ERNIE)的深度语义理解能力,以及文本卷积神经网络(Text Convolutional Neural Network, TextCNN)的局部特征提取能力,能够精准且灵活地应对新兴学科和交叉学科的复杂分类需求,为教育部一流学科的分类工作提供了一种新型解决方案,为“双一流”建设的科学推进提供技术保障。

1 相关研究

文献分类方法主要可分为传统机器学习方法和深度学习方法两大范式。传统机器学习方法以朴素贝叶斯^[1]、支持向量机^[2]和K近邻^[3]为代表,这些方法虽然在特定领域展现出较好的分类性能,但其本质上是基于浅层学习架构,严重依赖人工设计的特征工程。这种特征提取方式不仅需要领域专家的先验知识,而且难以有效捕捉文本中复杂的语义关联和非线性特征交互,在处理多义词、隐喻等复杂语言现象时表现欠佳。

随着深度学习技术的突破,基于神经网络的文本分类方法展现出显著优势。卷积神经网络^[4]通过多层卷积核自动提取文本的局部n-gram特征,实现了从字符级到句子级的层次化特征表示。循环神经网络^[5]及其改进型长短时记忆网络^[6]则通过门控机制解决了长距离依赖问题,能够更好地建模文本序列的时序特征。特别是Transformer架构的提出,开创了预训练语言模型的新纪元。以双向编码器表示模型(Bidirectional Encoder Representations from Transformers, BERT)为代表的预训练模型,通过掩码语言建模和下一句预测等预训练任务,在大规模语料库上学习到了丰富的语言表征,显著提升了模型对上下文语义的理解能力。

当前研究趋势表明,单一模型架构往往难以兼顾全局语义理解和局部特征提取的优势。因此,模型融合策略成为提升文本分类性能的重要研究方向。这类方法通过集成不同模型的互补优势,实现了分类性能的显著提升。例如,Lin等人^[7]提出的BertGCN将BERT的语义表示能力与图卷积网络的结构学习能力相结合,在文献分类任务中取得了突破性进展。Lu等人^[8]提出的VGCN-BERT模型进一步优化了这一思路,通过词汇图卷积网络实现了BERT不同层次特征的交互融合。刘琪等人^[9]提出的DeGraph-Net则引入了解耦注意力机制来增强模型的相对位置编码能力,在多个学术文献数据集上达到了较优的性能表现。这些融合方法不仅提升了分类准确率,也为理解文献的深层语义结构提供了新的研究视角。

除此之外,知识增强的预训练模型领域亦成为提升分类效果的有效探索方向。在知识增强的预训练模型方面,温阳^[10]等人提出的融合ERNIE与知识增强的文本分类模型,通过引入领域知识图谱的

结构化信息对 ERNIE 预训练语言模型进行语义增强,有效解决了专业术语理解不足的问题,在文本分类任务中展现出优于传统方法的领域适应性。李想^[11]等人提出的 BAG 模型进一步创新知识融合方式,通过构建文本与知识图谱的三重交互机制:实体对齐、图注意力聚合和知识感知决策,使模型能够充分利用学科关联网络等结构化知识,有效提升了跨领域文献分类的性能。上述研究表明,将知识图谱的结构化语义信息与预训练语言模型相结合,是提升学术文献分类效果的有效途径。

尽管基于 Transformer 的预训练模型及其复杂变体在文本分类任务中取得了些许成效,但模型选择需综合考虑任务特性、计算成本与性能增益的平衡。本研究选择 ERNIE 与 TextCNN 进行融合,主要基于三方面的考量。

ERNIE 在中文语义理解上具有优势。相较于通用 BERT 模型,ERNIE 通过掩码短语和实体级预训练任务,加深了对中文语言的理解。本研究处理的是富含专业术语和实体的人文社科文献,ERNIE 能更好地理解“理论经济学”、“社会资本”等领域概念的语义,为分类提供了更精准的上下文表征。

TextCNN 在局部特征捕捉上具有优势。学术文献,尤其是其标题、关键词和摘要,通常包含决定学科归属的关键性短语和术语组合。TextCNN 凭借其多尺度卷积核,能够捕捉这些关键的特征。虽然 Transformer 模型具备全局建模能力,但其注意力机制有时会过度平滑化局部显著信号。TextCNN 与 ERNIE 的结合,恰好在架构上形成了互补。ERNIE 提供全局的、富含知识的深度语义编码,而 TextCNN 则专注于提取与学科分类强相关的局部决定性模式。

综上所述,该组合充分利用了 ERNIE 在中文知识融合方面的特长和 TextCNN 在特征提取上的效率优势,为实现文献学科分类提供了一个性能与复杂度俱佳的解决方案。

2 文献分类任务研究

本文提出的 KG-ERNIE-TextCNN 模型由四部分组成,分别为嵌入层,编码层,特征提取层,输出层。本文模型的结构图如图 1 所示。

在嵌入层,模型采用实体链接技术^[12],将中文百科知识图谱与学科论文文本集^[13]深度融合,生成蕴含知识嵌入信息的句子树结构文本集。编码层利用预训练模型 ERNIE3.0^[14]对文本数据进行编码表示,生成蕴含上下文语义信息的高维词向量。特征提取层则通过 TextCNN 模型^[15],对词向量进行多

尺度卷积操作,提取局部语义特征,形成兼具细粒度与整体性的特征向量。输出层采用 Softmax 分类器,对特征向量进行分类预测。

2.1 选取通用知识图谱

为提升模型对学科领域的理解能力,本研究选用复旦大学知识工作实验室开发的 CN-DBpedia 知识图谱^[16]作为数据支撑。该知识库整合了千万级规范实体与数亿条语义关系,构建了涵盖社会、人文、经济等多领域的综合性知识体系。

借鉴 K-BERT 对 CN-DBpedia 数据处理方法^[17],本研究在实验数据预处理阶段,对实体名称长度小于 2 或包含特殊字符的三元组进行了过滤,得到了精简后的 CN-DBpedia 知识图谱,为后续模型训练提供了数据基础。




图 1 KG-ERNIE-TextCNN 模型结构图

Fig.1 Structure of KG-ERNIE-TextCNN model

2.2 学科论文数据集融合知识图谱

KG-ERNIE-TextCNN 模型的输入为由文献标题、摘要及关键词构成的原始文本。原始文本经分词处理后生成词序列,并通过实体链接技术从通用知识图谱中检索与文本实体相关的三元组信息。为增强语义边界的清晰性,模型将检索到的三元组按其在文本中的位置注入输入句子 $S = \{w_0, w_1, \dots, w_n\}$,构建句子树结构^[18]。若输入中实体 w_i 在知识图谱中存在关联三元组,则在实体 w_i 后嵌入对应三元组 (r_{i0}, w_{i0}) ,最终生成句子树结构如图 2 所示。




图2 句子树结构

Fig.2 Structure of the sentence tree

句子树的深度被固定设定为 1，即仅允许实体与其直接关联三元组进行连接，以避免因结构复杂化而引发的语义模糊问题。然而，直接注入外部知识可能对原始句子的可读性及语义表达产生干扰。为应对这一问题，模型引入了相对位置编码机制^[19]，旨在约束不同实体间的可见性。原始句子的词汇与知识图谱中被匹配到的三元组涉及绝对位置与相对位置信息，上述句子树对应两种位置如表 1 所示。

表1 绝对位置与相对位置

Table 1 Absolute and relative positions

	[CLS]	w_0	w_1	r_{10}	w_{10}	r_{11}	w_{11}	w_n
绝对位置	0	1	2	3	4	5	6	7
相对位置			2	3	4	3	4	

如表 1 所示，具备相对位置的实体仅对自身及临近的、同样具有相对位置的词汇可见，而同一词汇所匹配的不同三元组之间则不可见，例如 $\{r_{10}, w_{10}\}$ 与 $\{r_{11}, w_{11}\}$ 之间不可见。为了限制每个词汇的可见范围，本文构建了可视矩阵 M ，如图 3 所示。矩阵 M 的定义如下。

$$w_{ij} = \begin{cases} 0, w_i \square w_j \\ -\infty, w_i \oslash w_j \end{cases} \quad (1)$$

$w_i \square w_j$ 表示 w_i 与 w_j 相互可见， $w_i \oslash w_j$ 表示 w_i 与 w_j 相互不可见。根据表 1 结果计算出的可视矩阵^[20]如图 3 所示。可视矩阵中每个矩阵代表一个词汇，白色代表两个元素之间不可见，矩阵中数值为 $-\infty$ ，黑色代表可见，对应数值为 0。




图3 可视化矩阵

Fig.3 Visual matrix

可视矩阵在 ERNIE 层的自注意力计算中充当掩码，动态限制无关实体对注意力权重的贡献，从而抑制知识干扰。掩码自注意力^[21]的计算公式如公式(2)-(4)所示：

$$Q^{i+1}, K^{i+1}, V^{i+1} = h^i W_q, h^i W_k, h^i W_v \quad (2)$$

$$S^{i+1} = \text{Soft max}\left(\frac{Q^{i+1} K^{i+1} + M}{\sqrt{d_k}}\right) \quad (3)$$

$$h^{i+1} = S^{i+1} V^{i+1} \quad (4)$$

其中， W_q, W_k, W_v 是可训练模型参数； h^i 是第 i 个掩码自我注意力块的隐藏状态； d_k 是缩放因子； M 为可视矩阵的值。

2.3 ERNIE 预训练语言模型

预训练语言模型在自然语言处理 (Natural Language Processing, NLP) 领域取得了显著成果。ERNIE 是其中表现卓越的模型之一，其架构图如图 4 所示。




图4 ERNIE 模型架构图

Fig.4 Architecture diagram of the ERNIE model

在图 4 所展示的框架中，增强后的文本数据输入至 ERNIE 模型，并经历一系列步骤以提取其全局语义特征。

首先，文本数据经过 ERNIE 模型的嵌入层，该层负责将句子树结构中的词序列转换为稠密向量表示。在此过程中，模型融合了双重位置编码机制，以有效区分不同语义层次。其中，绝对位置编码机制确保了原始句子词序信息的完整保留；而相对位置编码则通过动态标记分支实体与主实体之间的偏移距离，实现了对全局结构与局部知识关联的协同建模。

紧接着，在 ERNIE 模型中改进的

Transformer-XL 模块内, 文本数据通过多层掩码自注意力机制进行深度编码。在每一层的自注意力计算过程中, 可视矩阵 M 发挥了关键作用, 它强制屏蔽了无关实体间交互作用, 有效约束了知识注入的边界, 避免了潜在语义噪声的干扰。

进一步地, 为提升模型对长文本依赖关系的建模能力, ERNIE 引入了段级递归机制。该机制通过缓存历史文本段的隐藏状态, 成功突破了传统的 Transformer 架构固定长度限制。同时, 模型还扩展了相对位置矩阵^[22], 在自注意力计算中量化词对之间的相对位置偏差, 以实现跨分支实体层次关系的精准捕捉。

最终, 经过多轮迭代计算, ERNIE 模型输出一个形状为 $[batch_size, seq_length, hidden_size]$ 的

全局语义矩阵。该矩阵表示每个批次中序列的隐藏状态维度, 为后续的 TextCNN 模块提供了兼具连贯性与领域适配性的深度语义表征。

2.4 TextCNN 模型

KG-ERNIE-TextCNN 模型的最后一个阶段由 TextCNN 模块完成多粒度特征提取与融合。TextCNN 是一种将卷积神经网络 (CNN) 应用于文本分类任务的模型。其核心思想是利用不同大小的卷积核提取句子中的关键信息, 从而更好地捕捉文本的局部相关性。

TextCNN 模型架构由卷积层、池化层及全连接层三大核心模块构成, 其结构示意图如图 5 所示。




图 5 TextCNN 模型原理图

Fig.5 Schematic diagram of TextCNN model

TextCNN 模型接收由 ERNIE 输出的全局语义矩阵作为输入, 并利用不同尺寸的卷积核以并行方式扫描文本序列, 以提取局部关键特征。每个卷积核均会生成特征图, 该特征图包含了在整个文本序列上提取的局部特征值。随后, 在池化层中, 通过全局最大池化操作从特征图中筛选出最显著的特征值, 并将这些特征值拼接后输入至全连接层, 进而将局部特征融合为全局特征表示。为缓解模型过拟合问题, 全连接层采用随机失活 Dropout 策略^[23], 随机失活部分神经元, 以降低神经元节点之间的相互依赖性, 增强模型的泛化能力。经过全连接层的处理后, 模型生成一个维度与学科类别数相一致的输出向量。最终, 该输出向量被输入至激活函数 Softmax^[24]进行特征缩放, 生成文献属于 21 个一级学科的概率分布。

综上所述, 三个模块的协同机制贯穿了整个 KG-ERNIE-TextCNN 模型。知识图谱通过实体链接与语义约束为 ERNIE 提供领域知识, 增强模型对学术论文中专业术语的理解。ERNIE 的深度编码为 TextCNN 捕捉文本的全局上下文信息, 确保局部特征提取与整体主题一致。而 TextCNN 的多尺度特征分类决策^[25], 使模型能够兼顾术语组合的细粒度差异与学科的整体语义。通过知识增强后的预训练语言模型与文本卷积神经网络的组合, 使得 KG-ERNIE-TextCNN 在学科分类任务中展现出较高的准确性与鲁棒性。

3 实验设计

为验证 KG-ERNIE-TextCNN 模型在文献学科分类任务中的有效性, 本研究从数据集构建, 实验

环境及评价指标和超参数的设置,分类模型对比实验分析,消融实验这四个部分设计实验。

3.1 数据集构建

本研究以教育部一流学科建设中社会科学文献分类为核心任务,严格采用《学位授予和人才培养学科目录》作为分类基准。这一研究框架的确立基于以下专业考量:在学科特性方面,社会科学领域具有显著的交叉学科特征和术语模糊性,导致学科分类具有较大误差;在数据选择方面,研究采用中国社会科学引文索引^[26](Chinese Social Sciences Citation Index, CSSCI)作为数据来源,该数据库作为国内人文社科领域的权威索引系统,不仅实施严格的文献质量筛选机制,其收录范围与教育部“双一流”建设学科中的人文社科类学科(如法学、教育学、经济学等)高度契合,从而确保了研究数据的学术代表性和分类体系的匹配性。而自然科学和应用科学领域的主要数据库(如CNKI、CSCD)采用《中国图书馆分类法》作为分类基准,与本研究基于教育部分类标准的体系存在显著差异,为了避免分类标准不一致导致的原始数据集误差,研究未涉及自然科学和应用科学领域数据。需特别说明的是,尽管《区域国别学》与《纪检监察学》亦属人文社科范畴,但鉴于其于2022年方才设立,相关文献资源匮乏,故暂未纳入本研究范畴。研究数据源自中国社会科学引文索引^[26](Chinese Social Sciences Citation Index, CSSCI)的文献资源。选择CSSCI作为数据源的理由如下:其一,CSSCI作为国内人文社科领域的核心期刊索引库,对文献质量实施严格筛选,从而保障了数据集的学术代表性^[27];

其二,教育部“双一流”建设学科中的人文社科类学科(诸如法学、教育学、经济学等)与CSSCI的收录范围高度契合^[28],为分类任务提供了有力的数据支撑。数据集构建流程包含以下步骤:

(1)初始数据获取与学科筛选:借助CSSCI的高级检索功能,按“学位分类”选项遍历所有学科,并将时间范围限定在2018年至2024年,逐年获取各学科对应的文献条目,最终汇总文献标题和关键词,以确保学科覆盖的广泛性与时序的代表性。

(2)文本信息清洗与补充:基于初始文献标题,在百度学术中编写定向爬虫程序^[29]进行二次检索。若标题完全匹配,则提取该文献的中文摘要;若匹配失败或摘要缺失,则舍弃该文献。此策略通过严格标题匹配,有效避免了摘要与原文不对应的问题。随后,删除摘要为空或非中文描述的文献条目,最终保留123499篇有效文献。

(3)学科平衡处理:鉴于军事类学科(如军事思想及军事历史、战略学等)的文献量低于其他学科(平均不足500篇),为避免类别不平衡^[30]对模型训练的干扰,决定移除相关文献。经此操作后,数据集涵盖人文社科主流学科共21类。

(4)数据集划分:采用随机分层抽样策略^[31],按4:1的比例将数据集划分为训练集(98792篇)与测试集(24707篇)。在划分过程中固定随机种子,以确保实验的可复现性。训练集用于模型参数优化,测试集用于评估模型的泛化性能。表2详细列出了各学科的训练集和测试集样本数量以及总数量。

表2 数据集分布
Table2 Distribution of data sets

一级学科	训练集	测试集	总数	一级学科	训练集	测试集	总数
法学	5480	1370	6850	新闻传播学	5436	1359	6795
工商管理	5456	1364	6820	艺术学	5404	1351	6755
公共管理	5248	1312	6560	应用经济学	5512	1378	6890
管理科学与工程	5084	1271	6355	哲学	5092	1273	6365
环境科学与工程	1908	477	2385	政治学	5164	1291	6455
教育学	5412	1353	6765	中国语言文学	5128	1282	6410
理论经济学	5380	1345	6725	军事思想及军事历史			222
历史学	3672	918	4590	军队政治工作学			17
民族学	3356	839	4195	军事后勤学与军事装备学			11
农林经济管理	996	249	1245	军队指挥学			51
社会学	5264	1316	6580	战略学			6
体育学	4992	1248	6240	军制学			2
图书馆.情报与档案管理	5284	1321	6605	战术学			1
外国语言文学	5096	1274	6370	战役学			1
心理学	4464	1116	5580				

3.2 实验环境与参数设置

3.2.1 实验环境

本试验所采用的编程语言为 python, 版本为 Python3.13, 框架为 Pytorch2.0.1, 实验使用电脑的 CPU 是 Intel Core i7-11700K。

3.2.2 参数设置

本文采用 KG-ERNIE-TextCNN 模型对文献数据进行分类实验。为提升分类效果, 对 ERNIE 模块的参数进行了针对性调整, 并通过网格搜索方法^[32]进行参数调优。优化后的参数设置详见表 3。

表 3 最佳超参数值

Table 3 Optimal hyperparameter values

参数名称	参数含义	参数值
max_length	最大文本长度	512
Learning Rate	学习率	1e-5
BATCH_SIZE	批量大小	16
filter_sizes	卷积核大小	[3,4,5,6]
Dropout	dropout 参数	0.2
Hidden_size	隐藏神经元个数	768

3.3 评价指标

本实验采用精确性 (Precision)、召回率 (Recall)、调和平均值 (F1) 作为模型性能评价指标^[33], 计算公式如下所示:

$$Precision = \frac{TP}{TP + FP} \quad (5)$$

$$Recall = \frac{TP}{TP + FN} \quad (6)$$

$$F1 = \frac{2 * Precision * Recall}{Precision + Recall} \quad (7)$$

上式中, TP 表示正确预测的正类样本数, FN 表示实际为正类但被预测为负类的样本数, FP 表示实际为负类但被预测为正类的样本数。

3.4 分类模型对比实验分析

为验证本文提出 KG-ERNIE-TextCNN 模型在教育一流学科文献分类任务中的性能优势, 本研究选取了六类主流文本分类模型作为对比基准。具体对比涵盖四类架构: 首先是基于卷积网络的模型, 包括区域卷积神经网络 (Region-based Convolutional Neural Network, RCNN) 和深度金字塔卷积神经网络 (Deep Pyramid Convolutional Neural Network, DPCNN) 两类模型; 其次是基于双向循环网络的模型, 包括了双向长短期记忆网络模型 (Bidirectional Long Short-Term Memory, BiLSTM) 和双向门控循环单元模型 (Bidirectional Gated Recurrent Unit, BiGRU); 然后是基于 Transformer 的预训练模型

RoBERTa、GPT-2; 最后是基于预训练语言模型的混合模型, 包括 BERT+TextCNN 模型和 ERNIE+BiGRU 模型。上述三类对比模型分别代表了卷积运算、序列建模和模型融合的不同技术路线, 能够系统检验模型在特征提取、长程依赖处理和语义理解等维度的性能差异。所有对比模型均在统一实验环境下运行, 并基于前文构建的数据集进行训练与测试。为确保对比的可靠性, 对各模型参数进行网格搜索调优, 覆盖学习率、批量大小、卷积核尺寸等关键参数, 并采用早停策略^[34]防止过拟合。为降低训练随机性干扰, 各模型独立运行 10 次并取平均值作为最终结果。

表 4 不同分类模型结果对比

Table 4 Comparison of results from different classification models

分类模型	Precision/%	Recall/%	F1/%
DPCNN	70.29	70.23	70.26
BiLSTM	70.54	70.23	70.38
RCNN	71.90	70.80	71.35
BiGRU	71.99	71.62	71.80
RoBERTa	74.85	74.62	74.72
GPT2	73.62	73.54	73.58
ERNIE+BiGRU	75.46	74.36	74.90
Bert+TextCNN	75.57	75.28	75.43
KG-ERNIE-TEXTCNN	77.68	77.62	77.65

(本文所提出的模型)

表 4 展示了 KG-ERNIE-TextCNN 模型与六类主流文本分类模型在精确率 (Precision)、召回率 (Recall) 及 F1 值上的对比结果。实验结果表明, 在教育部的一流学科文献分类任务中, 本文提出的 KG-ERNIE-TextCNN 模型以较大优势超越六类主流文本分类模型, 其精确率达 77.68%、召回率达 77.62%、F1 值达 77.46%, 均达到最优。相较于次优模型 BERT+TextCNN, KG-ERNIE-TextCNN 的精确率提升 2.11%、召回率提升 2.39%、F1 值提升 2.60%。相较于六类主流文本分类模型, 分类效果提升说明了 KG-ERNIE-TextCNN 模型具有较好的分类性能。该性能提升得益于知识增强型预训练语言模型与卷积神经网络的协同融合, 使模型在处理复杂学术文本时能够兼顾全局语义建模与局部特征提取, 从而显著提高了学术论文的分类精度和深层语义理解能力。

3.5 消融实验

为了进一步研究 KG-ERNIE-TextCNN 模型中各个组成部分对整个模型分类能力的贡献程度, 本研究通过构建以下四种模型并与原模型进行对比:

TextCNN 模型: 该模型只保留了 TextCNN, 移除了 KG 和 ERNIE 部分, 研究 TextCNN 自身在文献学科分类任务中的分类效果。

ERNIE 模型: 该模型只保留了 ERNIE, 研究 ERNIE 自身在文献学科分类任务中的分类效果。

KG-ERNIE 模型: 该模型只保留了 KG 和

ERNIE 部分, 移除 TextCNN, 研究 KG-ERNIE 的性能和知识增强的分类效果。

ERNIE-TextCNN 模型: 该模型保留了 ERNIE 和 TextCNN 的部分, 移除了知识图谱的部分, 研究 ERNIE-TextCNN 模型分类效果。

在相同的实验环境和超参数设置的条件下, 采用精确率 *Precision*、召回率 *Recall*、*F1* 值为评价指标进行实验, 得到的实验结果如表 5 所示。

表 5 消融实验结果

Table 5 Results of Ablation Experiment

模型	<i>Precision</i> / %	<i>Recall</i> / %	<i>F1</i> / %
TextCNN	71.16	70.94	71.05
ERNIE	75.76	74.81	75.29
KG-ERNIE	75.81	75.72	75.78
ERNIE-TextCNN	76.71	76.67	76.69
KG-ERNIE-TextCNN	77.68	77.62	77.65

如表 5 所示, 基于实验结果, 可得出以下结论:

ERNIE 模块的作用: 在基于 ERNIE 的实验中, 精确率达 75.76%, 召回率达 74.81%, *F1* 值为 74.84%。该结果表明, ERNIE 模型本身在文献分类任务中具备较大优势。在文本分类场景下, ERNIE 可作为核心模块发挥作用。对比 TextCNN 与 ERNIE-TextCNN 模型可知, 后者在三项分类指标上均实现超过 3.5% 的有效提升, 充分体现了 ERNIE 的全局语义建模能力对模型性能的关键作用。

表 6 KG-ERNIE-TextCNN 分类混淆矩阵

Table 6 Confusion matrix for KG-ERNIE-TextCNN classification

预测实际	法学	工商	公共	管科	环科	教育	理经	历史	民族	农经	社会	体育	图情	外语	心理	新传	艺术	应经	哲学	政治	中文
法学	1256	8	21	4	10	9	4	2	2	0	4	5	5	0	0	6	0	19	5	10	0
工商	3	1018	3	183	29	0	22	1	2	5	3	0	0	0	2	0	0	93	0	0	0
公共	20	11	793	30	58	48	14	8	87	27	80	0	6	2	4	34	0	48	5	35	0
管科	8	109	54	850	36	20	11	4	0	12	7	0	45	0	16	20	0	54	17	8	0
环科	4	22	2	8	389	0	18	2	0	6	0	0	0	0	0	1	0	18	1	6	0
教育	1	2	3	24	0	1230	3	3	6	0	11	1	4	10	26	6	0	1	8	13	0
理经	7	67	21	50	120	6	725	3	9	10	19	0	0	0	0	3	0	264	10	38	0
历史	16	0	2	2	15	4	676	54	0	12	0	13	6	0	4	22	14	20	31	24	0
民族	1	9	4	3	3	6	1	15	732	1	22	3	3	4	4	3	2	0	8	14	4
农经	0	7	8	0	16	0	5	0	3	187	5	0	0	0	0	0	0	18	0	0	0
社会	8	15	115	21	11	20	33	14	102	11	762	2	0	6	34	18	11	39	40	27	14
体育	0	0	0	0	0	5	0	0	2	0	0	1233	0	0	8	0	0	0	0	0	0
图情	15	0	5	73	2	7	0	10	4	0	0	2	1097	3	0	82	3	2	5	3	8
外语	2	1	0	1	0	2	0	1	2	0	1	0	1	1218	2	2	9	0	3	0	29
心理	1	8	2	61	1	12	0	0	0	0	23	7	1	3	962	14	0	2	19	0	0
新传	30	4	14	30	0	8	2	1	18	0	38	9	92	8	8	1028	22	6	19	14	6
艺术	1	0	0	2	0	25	0	10	39	0	13	1	2	18	3	30	1156	0	27	0	23
应经	13	127	49	45	75	9	107	0	6	125	28	0	3	0	0	1	0	779	2	9	0
哲学	7	0	5	19	2	21	24	27	16	0	10	0	0	22	22	6	10	0	1037	33	12
政治	18	0	66	15	17	23	40	12	39	3	24	0	7	2	0	15	1	14	33	962	0
中文	1	0	0	1	0	13	0	13	10	0	11	0	16	144	11	10	34	0	45	3	970

4 学科分析与模型改进

4.1 学科分析

为深入探究 KG-ERNIE-TextCNN 模型在 21 个学科中的分类性能差异及其成因, 本研究基于测试集分类结果的混淆矩阵, 从全局性能评估、分类错误与学

TextCNN 模块的作用: 通过对比 ERNIE 与 ERNIE-TextCNN 模型发现, TextCNN 的局部特征提取机制使三项指标均提升 0.5% 以上。尽管提升幅度有限, 但在术语密集型学科中, TextCNN 通过捕捉关键词组合仍能有效增强模型分类精度。

知识图谱 (KG) 模块的贡献: 对比 ERNIE 与 KG-ERNIE 模型的实验结果可知, 知识图谱的引入使 *F1* 值提升 1.04%, 精确率提升 1.27%, 召回率提升了 0.95%。该结果表明, 知识图谱通过实体对齐与语义约束机制, 有效增强了模型对交叉学科及领域术语的区分能力。

实验结果表明, KG-ERNIE-TextCNN 模型在分类性能上优于部分对比模型, 其精确率、召回率及 *F1* 值分别达到 77.68%、77.62% 和 77.46%, 超越了其他模型, 验证了模型各组成部分的有效性, 并凸显了知识图谱、ERNIE 预训练语言模型与 TextCNN 卷积网络的协同效应。知识图谱嵌入增强了 ERNIE 的语义表征能力, TextCNN 模块的引入则提升了多尺度文本特征的提取精度, 最终促使文献分类性能达到较优水平, 展现出卓越的分类效能。

尽管 KG-ERNIE-TextCNN 模型在对比实验中表现优异, 但精确率等核心指标尚未突破 80% 阈值。为此, 本研究进一步开展学科领域细分分析, 旨在探究模型在不同学科场景下的适用性及优化方向。

科交叉性分析^[35]两个维度展开分析。表 6 为分类结果的分布矩阵, 为了便于分析, 本研究对于学科名简化为: 工商管理-工商; 公共管理-公共; 管理科学与工程-管科; 环境科学与工程-环科; 理论经济学-理经; 农林经济管理-农林; 图书馆、情报与档案管理-图情; 外国语言文学-外语; 新闻传播学-新传; 应用经济学-应经; 中国语言文学-中文。

首先进行全局分类性能评估。从分类矩阵混淆来看,各学科类别的预测正确数量占据总数量的主导地位,表明模型整体分类效果良好。例如,法学类别的预测正确数量为 1256,正确分类占比达 90.09%;外语类别的预测正确数量为 1218,正确分类占比达 95.60%,这验证了 KG-ERNIE-TextCNN 模型在术语明确、主题聚焦的学科分类任务中具有较好的表现。

针对错误分类与学科交叉性进行深入分析。通过对分类错误的学科进行剖析,并结合学科特征探讨语义混淆的原因,发现以下两类主要问题:

(1) 强交叉性学科间的双向误判现象。例如,理论经济学被错误预测为应用经济学的数量为 264,占总样本比例为 19.16%;应用经济学被错误预测为工商类的数量为 107,占总样本比例为 7.95%。这两类学科均聚焦于经济现象的研究与解释,学科间的高度交叉性导致语义边界模糊,进而引发误判。

(2) 跨领域交叉导致的广泛误判问题突出。例如,社会学被错误预测为公共管理的数量为 115,占总样本比例的 8.73%;社会学被错误预测为民族学的数量为 102,占总样本比例的 7.75%。社会学研究常涉及公共政策与民族文化,文本中出现的“政策”“民族”“社会结构”等跨领域术语易引发语义歧义,从而导致误判。

为了更直观地呈现不同学科的分类性能差异,本研究将所有一流学科的测试集分类准确率按从低到高排序,并绘制出相应的柱形图,如图 6 所示,以对比学科间的精确率,区分较易分类和分类难度较高的学科,从而为后续优化提供明确方向。




图 6 KG-ERNIE-TextCNN 学科分类效果对比

Fig.6 Comparison of subject classification effectiveness of KG-ERNIE-TextCNN

根据图 6 的测试集分类准确率对比,可以发现不同学科的预测效果差异可以按照 F1 值大小分为高准确率学科、中等准确率学科和低准确率学科。

高准确率学科 (80%-100%): 体育学、外语学、法学、教育学、民族学、艺术学、图书馆情报与档案管理、环境科学与工程、哲学的预测效果最优,体现了模型对领域术语明确、主题聚焦的文献具备极强的分类能力。

中等准确率学科 (70%-80%): 中国语言文学、新闻学、农林经济管理、工商管理、政治学、历史学的预测效果较好,但存在跨学科误判。

低准确率学科 (70%以下): 管理科学与工程、理论经济学、公共管理、应用经济学及社会学等学科的分类效果欠佳,反映出模型在识别具有高度交叉性的一级学科时存在困难。

4.2 模型改进

经 4.1 节学科细分分析可知,学科交叉性对模型分类性能存在负面影响。基于此,本文将从学科交叉性解析、专业领域知识图谱增强及多模型对比优化三个部分进行模型改进。

4.2.1 学科交叉性分析

为系统揭示学科间交叉关联^[36],本研究基于测试集文本数据,采用层次聚类算法对 21 个学科进行聚类分析。具体步骤如下:首先使用 ERNIE 模型输出各学科的句子向量,并对同一学科句子向量求均值得到该学科的向量表示,接着使用层次凝聚聚类方法^[37]进行聚类,聚类结果如图 7 所示。

从图 7 可见,理论经济学与应用经济学间的距离最短,表明二者具有最高相似性,优先被聚类。此外,工商管理与管理科学与工程、公共管理与社会学等学科类别亦展现出较高相似性。表 6 进一步揭示,相似性较高的学科类别在预测过程中易出现分类混淆。结合图 7 的聚类分析和表 6 的混淆类别统计,本文提炼出三组交叉性较强的学科对:公共管理-社会学、应用经济学-理论经济学、管理科学与工程-工商管理。

4.2.2 专业领域知识图谱构建

针对存在交叉现象的学科对,本文构建专业领域知识图谱 (Domain-specific Knowledge Graph, DKG),以增强模型对细分领域术语的语义理解能力。本文使用 Bert-条件随机场^[38] (Conditional Random Field, CRF) 模型从 2018-2024 年交叉性较强的 6 个学科 (公共管理、管理科学与工程、理论经济学、社会学、应用经济学、工商管理) 论文中提取实体,每个学科定义十种实体属性。将抽取的实体与实体属性相对应组成三元组,最终构建 24831 组三元组。




图7 不同学科聚类结果

Fig.7 Clustering results for different disciplines

表7 实体关系对应

Table7 Correspondence of Entity Relationships

实体	实体关系	实体属性
社会工作者	属于	社会组织
邻里疏离	属于	社会问题
数字鸿沟	属于	社会变迁

例如对于社会学样例的表达“城市社区治理中,社会工作者、社区组织和地方政府等多元主体协同应对老龄化、邻里疏离和公共服务不均等社会问题,而这一过程又受到数字鸿沟和社会资本等因素的显著影响。”Bert-CRF 从该句子中可以识别以下实体,如表7所示。

4.2.3 模型改进分析

为验证专业领域知识图谱的有效性,本文在相同的实验环境和超参数条件设置下对比了本文原 KG-ERNIE-TextCNN 模型与增加 DKG 知识图谱后 KG-ERNIE-TextCNN 的分类性能,结果如表8所示。

表8 DKG 增强前后的分类结果对比

Table 8 Comparison of classification results before and after DKG enhancement

	Precision	Recall	F1
中文百科 KG	77.68	77.62	77.46
专业领域 DKG+ 中文百科 KG	78.56	78.93	78.15

对比专业领域知识图谱增强前后模型的性能,表8的结果显示,经 DKG 增强的模型在 Precision、Recall 及 F1 三个评估指标上均优于原模型。专业领域 DKG 的 Precision 指标达到 78.56%, Recall 为 78.93%, F1 综合指标为 78.15%,相较于中文百科知识图谱的对应指标,均实现超过 0.5% 的提升。进一步考察学科领域知识图谱嵌入对模型交叉性学科分类性能的影响,选取与学科领域知识图谱紧密相关的六个学科进行深入分析。交叉性学科在知识图谱嵌入前后

的分类性能对比结果如图8所示。




图8 交叉性学科的 F1 值对比

Fig.8 Comparison of F1 values for interdisciplinary disciplines

在图8中,在引入学科领域知识图谱嵌入后,各个学科的 F1 值均有不同程度提升。其中,管理的 F1 值从 66.8% 提高至 71.8%,公共从 60.4% 提升至 63.8%,社会从 57.9% 上升至 61.2%,应用从 56.5% 升至 60.7%,理论从 53.9% 提高至 59.8%,工商管理从 74.6% 进一步提升至 76.3%, F1 值平均提升了 3.9%,结果表明模型对学科边缘样本的识别能力增强,尤为重要的是,交叉性学科的区分度有了一定程度提升,验证了学科领域知识图谱嵌入在处理学科交叉性的有效性。整体来看,学科领域知识图谱嵌入有效增强了模型对交叉性学科语义特征的识别能力,改善了分类性能,验证了领域知识在复杂语境下对文本表示与推理的积极作用。

5 结语

随着“双一流”建设战略的持续深化,教育部一流学科的分类与评估已成为学术界及教育管理领域的核心议题。本研究提出的 KG-ERNIE-TextCNN 模型,通过有机融合知识图谱增强技术、ERNIE 预训练语言模型与 TextCNN 多尺度特征提取方法,有效提升了一级学科分类的精准度。实验结果显示,该模型在 21 个一级学科分类任务中实现了 77.46% 的宏 F1 值,相较于最优基线模型提升了 2.6%。

尤为突出的是,针对公共管理与社会学等存在交叉性现象的学科领域,本研究构建了专业领域知识图谱(DKG),使得模型 F1 值进一步攀升至 78.15%,交叉学科平均误判率降低,充分彰显了模型在处理交叉性较强学科分类任务中的卓越能力。消融实验结果进一步验证了知识图谱嵌入与模块协同机制的有效性。

本研究实现了知识图谱、ERNIE 预训练语言模型与 TextCNN 结构的深度融合,并针对交叉学科文本中术语复杂、边界模糊等挑战,构建并引入了专业领域知识图谱。首先,通过整合学科领域与通用知识图谱,

借助实体链接与语义对齐机制,强化了模型对专业术语语义的先验认知,为后续语义建模奠定了坚实的知识基础;其次,依托 ERNIE 的语义增强能力,深入挖掘词语在上下文中的依存关系与深层含义,结合知识图谱信息形成结构化语义表示,有效提升了模型对跨领域术语语义漂移的适应力;最后,融合 TextCNN 模型的局部感知特性,对多粒度语义特征进行精准提取与分类判断,实现了对局部模式与全局结构的协同捕捉。三者协同作用,既保证了外部知识注入的广度,又兼顾了语义表达的深度与模式识别的精度,从而有效提升了模型在交叉学科文本分类任务中的表现力与泛化能力。

尽管本研究取得了一些成果,但仍存在三方面局限性:其一,对数字人文等新兴交叉学科的适应性尚需提升;其二,知识图谱的时效性维护面临挑战;其三,长尾学科的分类性能仍有优化空间。针对上述局限,未来研究将围绕以下三个方向展开:构建动态知识图谱更新机制,结合主动学习实现领域知识的持续迭代;深化特定学科对的实体关系标注,如扩展公共管理-社会学等领域的专业知识图谱;探索层次化多任务学习框架,通过引入学科树状结构和辅助预测任务增强模型区分力。

本研究成果不仅为“双一流”建设中的学科评估提供了坚实的技术支撑,其方法论框架在学术资源组织、知识服务等领域亦展现出重要的应用价值。后续工作将聚焦于提升模型在动态学术生态中的适应能力,为推动学术文献智能分类的创新发展提供新思路。

参考文献

- [1] KIM S B, HAN K S, RIM H C. Some Effective Techniques for Naive Bayes Text Classification[J]. IEEE Transactions on Knowledge and Data Engineering, 2006, 18(11): 1457-1466.
- [2] CORTES C, VAPNIK V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.
- [3] ALTMAN N S. An introduction to kernel and nearest-neighbor nonparametric regression[J]. The American Statistician, 1992, 46(3): 175-185.
- [4] KIM Y. Convolutional Neural Networks for Sentence Classification[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar, 2014: 1746-1751.
- [5] LIU P, QIU X, HUANG X. Recurrent Neural Network for Text Classification with Multi-Task Learning[C]//Proceedings of the 25th International Joint Conference on Artificial Intelligence (IJCAI). New York, USA, 2016: 2873-2879.
- [6] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [7] 孟祥福, 任全莹, 杨东桑, 等. 基于 BERT 和 CNN 的药物不良反应个例报道文献分类方法[J]. 计算机科学, 2024, 51(6A): 230400049.
- [8] LU Z, DU P, NIE J. VGCN-BERT: Augmenting BERT with graph embedding for text classification[J/OL]. arXiv: 2004.05707, 2020[2025-04-08]. <https://arxiv.org/abs/2004.05707>.
- [9] 刘琪, 肖克晶, 曹少中, 等. 融合 DeBERTa 模型与图卷积网络的文本分类方法研究[J]. 人工智能与机器人研究, 2024, 13(4): 715-725.
- [10] LIU Q, XIAO K J, CAO S Z, et al. Research on Text Classification Methods by Fusing DeBERTa Model with Graph Convolutional Networks[J]. Artificial Intelligence and Robotics Research, 2024, 13(4): 715-725.
- [11] 温浩, 杨洋. 融合 ERNIE 与知识增强的临床短文本分类研究[J]. 计算机工程与应用, 2025, 61(8): 108-116.
- [12] WEN Hao, YANG Yang. Research on Clinical Short Text Classification by Integrating ERNIE with Knowledge Enhancement[J]. Computer Engineering and Applications, 2025, 61(8): 108-116.
- [13] 李想, 马致远, 汪伟, 等. BAG: 基于注意力机制融合 Bert 和 GCN 的文本分类模型[J]. 软件工程与应用, 2023, 12(2): 230-241.
- [14] LI X, MA Z Y, WANG W, et al. BAG: Text Classification Based on Attention Mechanism Combining BERT and GCN[J]. Software Engineering and Applications, 2023, 12(2): 230-241.
- [15] WANG X Z, GAO T Z, ZHU Z C, et al. KEPLER: A unified model for knowledge embedding and pre-trained language representation[C]// Proceedings of the Association for Computational Linguistics. Stroudsburg: ACL, 2021, 9: 176-194.
- [16] 刘知远, 孙茂松, 林衍凯, 等. 知识表示学习研究进展[J]. 计算机研究与发展, 2016, 53(2): 247-261.
- [17] LIU Z Y, SUN M S, LIN Y K, et al. Knowledge Representation Learning: A Review[J]. Journal of Computer Research and Development, 2016, 53(2): 247-261.
- [18] SUN Y, WANG S H, LI Y K, et al. ERNIE: Enhanced representation through knowledge integration[OL]. 2019[2025-04-08]. <https://arxiv.org/abs/1905.07129>.
- [19] KIM Y. Convolutional neural networks for sentence classification[C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2014: 1746-1751.
- [20] XU B, XU Y, LIANG J, et al. CN-DBpedia: A never-ending Chinese knowledge extraction system[C]//International Conference on Industrial, Engineering and Other Applications of Applied Intelligent Systems. Cham: Springer, 2017: 428-438.
- [21] LIU W, ZHOU P, ZHAO Z, et al. K-BERT: Enabling language representation with knowledge graph[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2020, 34(3): 2901-2908.
- [22] ZHANG N, DENG S, SUN Z, et al. Relation adversarial network for low resource knowledge graph completion[C]//Proceedings of the Web Conference 2020. New York: ACM, 2020: 1-12.
- [23] SHAW P, USZKOREIT J, VASWANI A. Self-attention with relative position representations[C]// Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2018: 464-468.
- [24] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. Long Beach: NeurIPS, 2017: 5998-6008.

- [21] DAI Z, YANG Z, YANG Y, et al. Transformer-XL: Attentive language models beyond a fixed-length context[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2019: 2978-2988.
- [22] ZHANG Z, HAN X, LIU Z, et al. ERNIE: Enhanced language representation with informative entities[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2019: 1441-1451.
- [23] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [24] LIU X, HE P, CHEN W, et al. Multi-task deep neural networks for natural language understanding[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2019: 4487-4496.
- [25] YANG Z, YANG D, DYER C, et al. Hierarchical attention networks for document classification[C]//Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2016: 1480-1489.
- [26] 苏新宁.中文社会科学引文索引(CSSCI)的设计与应用价值[J].中国图书馆学报,2012,38(5):95~102.
- SU X N. The Design and Application Value of the Chinese Social Sciences Citation Index[J]. Journal of Library Science in China, 2012,38(5):95~102.
- [27] 肖珑.支持“双一流”建设的高校图书馆服务创新趋势研究[J].大学图书馆学报,2018,36(05):43-51.
- XIAO L. Service innovation trends of academic libraries supporting the "Double First-Class" initiative[J]. Journal of Academic Librar, 2018, 36(05): 43-51.
- [28] 吴爱芝,肖珑,张春红,等.基于文献计量的高校学科竞争力评估方法与体系[J].大学图书馆学报,2018,36(01):62-67+26.
- WU A Z, XIAO L, ZHANG C H. Literature metrics-based evaluation method and system for university discipline competitiveness[J]. Journal of Academic Library, 2018, 36(01): 62-67+26.
- [29] PANDEY M, RAUTARAY S S. A comprehensive study on web scraping techniques and tools[J]. International Journal on Future Revolution in Computer Science & Communication Engineering, 2018, 4(4): 364-371.
- [30] BUDA M, MAKI A, MAZUROWSKI M A. A systematic study of the class imbalance problem in convolutional neural networks[J]. Neural Networks, 2018, 106: 249-259.
- [31] KOHAVI R. A study of cross-validation and bootstrap for accuracy estimation and model selection[C]//Proceedings of the 14th International Joint Conference on Artificial Intelligence. San Francisco: Morgan Kaufmann, 1995: 1137-1143.
- [32] BERGSTRA J, BENGIO Y. Random search for hyper-parameter optimization[J]. Journal of Machine Learning Research, 2012, 13(1): 281-305.
- [33] SOKOLOVA M, LAPALME G. A systematic analysis of performance measures for classification tasks[J]. Information Processing & Management, 2009, 45(4): 427-437.
- [34] PRECHTEL L. Early stopping-but when?[M]//Neural Networks: Tricks of the Trade. Berlin: Springer, 1998: 55-69.
- 于洋,张睿军,杨亚楠.以情报学为视角的学科交叉研究[J].情报杂志,2013,32(02):1-5+33.
- WANG F Y, WANG X, ZHANG J. A Research of Interdiscipline based on Information Science[J].Journal of intelligence, 2013, 32(02): 1-5+33.
- [36] 冯岭.结合文本聚类和多标签分类的学科交叉主题早期识别方法[J].情报杂志,2024,43(08):160-169.
- FENG L. Early Identification Method of Interdisciplinary Topics based on Text Clustering and Multi-Label Classification[M].Journal of intelligence, 2024, 43(08): 160-169.
- [37] MANNING C D, RAGHAVAN P, SCHÜTZE H. Introduction to Information Retrieval[M]. Cambridge: Cambridge University Press, 2008: 420-435.
- [38] 李书琴,庞文婷.词嵌入BERT-CRF玉米育种实体关系联合抽取方法[J].农业机械学报,2023,54(11):286-294.
- LI S Q, PANG W T. Joint Extraction Method of Entity and Relation in Maize Breeding Based on BERT-CRF and Word Embedding[J].Transactions of the Chinese Society of Agricultural Machinery, 2023, 54(11): 286-294.